

Analisi PLS Regression Farine Animali NIR

Regressione PLS / PLS-DA per la classificazione di farine animali (pollo, bovino, pesce) tramite spettroscopia NIR

Dataset	farineanimNIR.mat (84 campioni × 2001 wavenumbers)
Range spettrale	6000 – 4000 cm ⁻¹ (NIR)
Classi	Pollo, Bovino, Pesce
Metodo	PLS-DA (Partial Least Squares Discriminant Analysis)
Cross-Validation	Venetian Blind (15 splits, thickness = 3)
Software	MATLAB + PLS Toolbox (Eigenvector Research Inc.)
Data generazione	21/02/2026 09:51

Indice

PCA Esplorativa

1. Score Plot PC1 vs PC2
2. Loading Plot
3. T^2 vs Q — Outlier Detection
4. Spettri NIR Originali

Selezione Numero LV

5. Scree Plot — Scelta Numero LV

Modello PLS Finale

7. T^2 vs Q (PLS)
8. Score Plot LV1 vs LV2
9. Y Predetto vs Y Misurato
10. Residui Cross-Validation
11. Leverage vs Residuals
12. Inner Relations

Importanza Variabili

13. PLS Weights
14. Coefficienti di Regressione
15. VIP Scores
16. Selectivity Ratio

Validazione

17. Test Set Prediction
18. Confusion Matrix
19. Spettri Preprocessati vs Originali

1. PCA Esplorativa — Score Plot (PC1 vs PC2)




Figura: 01_PCA_scores_PC1_PC2.png

Lo score plot della PCA esplorativa (con solo mean centering) mostra la proiezione dei campioni nel sotto-spazio a 2 componenti principali. **PC1** spiega tipicamente la quasi totalità della varianza (>99%) e cattura effetti fisici quali variazioni di *scattering* e spostamenti di baseline, che colpiscono uniformemente l'intero spettro NIR.

In questo grafico si osserva la distribuzione dei campioni colorati per classe (pollo, bovino, pesce). Se le classi non sono ben separate lungo PC1, ciò conferma che la prima componente è dominata da variazioni fisiche piuttosto che chimiche, e indica la necessità di un preprocessing spettrale (es. derivate, SNV, MSC) per rimuovere questi effetti prima di costruire il modello PLS.

2. PCA Esplorativa — Loading Plot




Figura: 02_PCA_loadings.png

I loadings mostrano il contributo di ciascun wavenumber alle componenti principali.

Loading PC1 (blu): Un profilo quasi piatto o monotono indica che PC1 cattura variazioni fisiche (scattering, baseline shift) che influenzano uniformemente lo spettro. Questo è coerente con il fatto che PC1 spiega una percentuale enorme della varianza.

Loading PC2 (rosso): Nonostante spieghi poca varianza, presenta picchi e valli ben definiti, indicatori di variazione chimica reale: le regioni con loadings elevati corrispondono a bande di assorbimento di gruppi funzionali come O-H ($\sim 5200 \text{ cm}^{-1}$), N-H ($\sim 4600 \text{ cm}^{-1}$) e C-H ($\sim 4300 \text{ cm}^{-1}$), legati a differenze nel contenuto di acqua, proteine e grassi tra le categorie.

3. PCA Esplorativa — T^2 vs Q (Outlier Detection)




Figura: 03_PCA_T2_vs_Q.png

Il grafico T^2 vs Q permette di identificare campioni anomali (outlier).

T^2 (Hotelling): Misura quanto un campione si discosta dal centro del modello nello spazio delle PC selezionate. Valori elevati indicano campioni con variazioni estreme *dentro* il modello.

Q (Residui): Misura quanto un campione non è spiegato dal modello. Valori elevati indicano campioni che il modello non riesce a descrivere bene (diversità strutturale).

Campioni con T^2 alto e Q basso sono spiegati dal modello ma sono estremi; campioni con T^2 basso e Q alto non sono ben descritti; campioni con entrambi alti sono i più critici. Questa analisi è fondamentale per decidere se escludere outlier prima di costruire il modello PLS.

4. Spettri NIR Originali




Figura: 04_spettri_originali.png

A sinistra sono mostrati tutti gli spettri NIR originali, colorati per classe. Si possono osservare le differenze globali tra i gruppi e la sovrapposizione nelle regioni comuni.

A destra gli spettri medi per categoria evidenziano le differenze sistematiche. Le regioni di maggior interesse nel mid-NIR (6000-4000 cm^{-1}) includono:

- **~5200 cm^{-1}** : Combinazione O-H (acqua)
- **~4600 cm^{-1}** : Combinazione N-H (proteine)
- **~4300 cm^{-1}** : Combinazione C-H (lipidi, carboidrati)

Le differenze tra gli spettri medi sono spesso sottili e mascherate da effetti di scattering, giustificando il preprocessing spettrale.

5. Scree Plot — RMSEC e RMSECV vs Numero LV




Figura: 05_scree_plot_LV.png

Lo scree plot confronta l'errore in calibrazione (RMSEC, blu) con l'errore in cross-validation (RMSECV, rosso) al variare del numero di LV, utilizzando il preprocessing scelto (SNV + Mean Centering).

Criterio di scelta del numero di LV: Si seleziona il numero di LV corrispondente al "gomito" della curva RMSECV, cioè il punto dopo il quale aggiungere ulteriori LV non produce un miglioramento significativo dell'errore di CV, o peggio, lo aumenta (overfitting).

SNV (Standard Normal Variate) corregge gli effetti di scattering moltiplicativo e additivo tipici degli spettri NIR, normalizzando ciascuno spettro per la propria media e deviazione standard. Dopo SNV, il **Mean Centering** centra i dati sull'origine, facilitando la decomposizione PLS.

Se RMSEC continua a scendere mentre RMSECV si stabilizza o sale, siamo in presenza di overfitting: il modello impara rumore dai dati di calibrazione senza migliorare la capacità predittiva. La linea verticale tratteggiata indica il numero di LV selezionato.

7. Modello PLS — T^2 vs Q




Figura: 07_T2_vs_Q_PLS.png

Analoga al T^2 vs Q della PCA, ma calcolata sul modello PLS finale. Si verificano:

- **Accumulo intorno allo zero:** La maggior parte dei campioni si concentra a bassi valori di T^2 e Q , indicando che il modello li descrive bene.
- **Campioni con T^2 elevato ma Q basso:** Sono campioni estremi ma ben spiegati dal modello (variazioni chimiche reali, non errori).
- **Campioni con Q elevato:** Non ben descritti dal modello, possono indicare contaminazioni o errori sperimentali.

Le linee tratteggiate rosse indicano i limiti di confidenza al 95%. Campioni oltre entrambi i limiti sono potenziali outlier da investigare.

8. Score Plot PLS — LV1 vs LV2




Figura: 08_scores_LV1_LV2.png

Lo score plot nello spazio delle Latent Variables del PLS mostra come il modello separa le classi. A differenza della PCA, che massimizza la varianza di X, le LV del PLS massimizzano la covarianza tra X e Y, quindi la separazione tra classi dovrebbe essere migliore.

Gruppi ben separati indicano che il modello ha trovato pattern spettrali discriminanti tra le categorie. La posizione relativa dei cluster fornisce informazioni sulla somiglianza tra classi: categorie vicine hanno profili spettrali simili.

9. Y Misurato vs Y Predetto (per classe)




Figura: 09_01_Y_pred_vs_meas_Bovino.png

Per ciascuna classe (variabile dummy), il grafico confronta i valori misurati (0 o 1) con i valori predetti dal modello, sia in **calibrazione (fit)** che in **cross-validation**.

Pannello sinistro (Fit): Mostra la capacità del modello di riprodurre i dati di training. La linea verde è la diagonale perfetta ($y=x$), la linea rossa è la regressione effettiva. Maggiore è la sovrapposizione tra le due linee, migliore è il fit.

Pannello destro (CV): Misura la capacità predittiva lasciando fuori campioni uno alla volta (o a gruppi). Se il pattern è simile al fit, non c'è overfitting. Il valore R^2 in CV è la metrica più affidabile per valutare la bontà predittiva.

11. Leverage vs Y Residuals




Figura: 11_leverage_vs_residuals.png

Il grafico Leverage vs Residui è uno strumento diagnostico per identificare campioni influenti.

Leverage (asse x): Misura quanto un campione influenza il modello. Campioni con leverage elevato hanno un peso sproporzionato nella costruzione del modello.

Residui Y (asse y): Errore di predizione per quel campione.

Campioni con *alto leverage e alti residui* sono i più problematici: influenzano fortemente il modello ma non sono predetti bene. Idealmente, i punti devono concentrarsi vicino all'origine con residui entro la banda $\pm 3\sigma$.

12. Inner Relations (T scores vs U scores per LV)




Figura: 12_inner_relations.png

Le inner relations mostrano la relazione tra X-scores (T) e Y-scores (U) per ogni Latent Variable. Nel modello PLS, la relazione $T \rightarrow U$ deve essere lineare.

- **Prime LV:** Mostrano tipicamente una struttura lineare forte (alto coefficiente di correlazione r), indicando che catturano la maggior parte dell'informazione predittiva.
- **LV successive:** La struttura lineare si attenua, il contributo informativo diminuisce.

Se le ultime LV non mostrano relazione lineare, il loro contributo predittivo è minimo e si potrebbe considerare un modello con meno LV. Questo grafico conferma la scelta del numero di LV effettuata con lo scree plot.

14. Coefficienti di Regressione PLS




Figura: 14_regression_coefficients.png

I coefficienti di regressione forniscono una visione sintetica di come ogni wavenumber contribuisce alla predizione di ciascuna classe. Il profilo oscillante, con alternanza di regioni positive e negative, è tipico dei modelli PLS su dati spettrali.

Valori con modulo elevato (picchi e valli) indicano le lunghezze d'onda dove le variazioni dello spettro sono più fortemente correlate all'appartenenza a una specifica classe.

Nelle regioni NIR 4000-6000 cm^{-1} , i coefficienti di maggior modulo dovrebbero localizzarsi in corrispondenza delle bande di overtone **N-H** (proteine), **O-H** (acqua) e **C-H** (lipidi), che differenziano il contenuto nutritivo di pollo, bovino e pesce.

15. VIP Scores (Variable Importance in Projection)




Figura: 15_VIP_scores.png

Il VIP (Variable Importance in Projection) è una misura cumulativa dell'importanza di ciascuna variabile nella proiezione PLS. La formula considera il peso di ogni variabile in ogni LV, ponderato per la varianza di Y spiegata da quella LV.

Soglia VIP = 1: Variabili con $VIP > 1$ contribuiscono in media più della media alla predizione di Y. Es. un valore VIP di 1.5 indica che quella variabile è 50% più importante della media.

Le regioni con VIP elevato identificano le bande spettrali più informative per la classificazione. Questo è particolarmente utile per l'interpretazione chimica: le bande NIR con $VIP > 1$ corrispondono ai gruppi funzionali che differenziano le tre classi di farine animali.

17. Validazione Test Set — Y Predetto vs Y Misurato




Figura: 17_test_set_prediction.png

Questo è il grafico più importante dell'intera analisi: mostra la capacità del modello di predire campioni **mai visti** durante la fase di calibrazione.

Per ciascuna classe, i punti devono distribuirsi lungo la diagonale (linea verde). Il valore **RMSEP** (Root Mean Square Error of Prediction) quantifica l'errore medio di predizione, mentre **R^2** misura la quota di varianza spiegata nei dati di test.

Interpretazione:

- $RMSEP \approx RMSECV \rightarrow$ il modello generalizza bene (no overfitting)
- $RMSEP \ll RMSECV \rightarrow$ test set troppo "facile" o fortunato
- $RMSEP \gg RMSECV \rightarrow$ overfitting, il modello non generalizza

Valori di $R^2 > 0.90$ e bassa dispersione attorno alla diagonale indicano un modello con eccellente capacità di generalizzazione.

18. Confusion Matrix — Calibrazione e Test Set




Figura: 18_confusion_matrix.png

La Confusion Matrix riassume le prestazioni di classificazione in formato tabellare. Ogni riga rappresenta la classe vera, ogni colonna la classe predetta dal modello.

Diagonale: Campioni correttamente classificati. Idealmente, tutti i campioni dovrebbero trovarsi sulla diagonale.

Fuori diagonale: Errori di classificazione (misclassificazioni). Indicano quali classi il modello confonde più facilmente. Ad esempio, confusione tra bovino e pollo potrebbe indicare profili proteici simili, mentre il pesce ha tipicamente un profilo lipidico molto diverso.

L'accuratezza complessiva (percentuale di campioni correttamente classificati) è riportata nel titolo di ciascun pannello. Un buon modello PLS-DA su dati NIR raggiunge tipicamente accuratze del 85-100%.

19. Spettri Originali vs Preprocessati




Figura: 19_spettri_preprocessati.png

Questo confronto visuale mostra l'effetto del preprocessing spettrale selezionato.

Pannello sinistro (Originali): Gli spettri grezzi mostrano ampia variabilità dovuta a effetti fisici (scattering, dimensione particelle, baseline shift) che mascherano le differenze chimiche.

Pannello destro (Preprocessati): Dopo il preprocessing, le variazioni fisiche vengono ridotte/eliminate, esaltando le differenze chimiche tra le classi. La derivata seconda rimuove offset e trend lineari, la MSC normalizza lo scattering, e il mean centering centra i dati. Il risultato sono spettri dove le differenze tra pollo, bovino e pesce sono più evidenti e interpretabili in termini di composizione chimica.

Conclusioni

L'analisi PLS-DA condotta sugli spettri NIR delle farine animali ha dimostrato l'efficacia della spettroscopia nel vicino infrarosso per la classificazione di campioni di diversa origine (pollo, bovino, pesce).

Risultati principali:

- PCA Esplorativa:** La dominanza di PC1 (varianza >99%) ha confermato la necessità di preprocessing spettrale per rimuovere gli effetti fisici di scattering.
- Preprocessing:** Si è applicato il preprocessing **SNV + Mean Centering**. L'SNV corregge gli effetti di scattering tipici degli spettri NIR, mentre il mean centering centra i dati sull'origine, facilitando la decomposizione PLS e l'interpretazione dei risultati.
- Modello PLS:** La cross-validation con schema Venetian Blind (15 split, thickness 3) ha garantito una stima robusta della capacità predittiva. L'analisi dei grafici diagnostici (T^2 vs Q, leverage, residui) conferma la validità e stabilità del modello.
- Importanza Variabili:** VIP, Selectivity Ratio e coefficienti di regressione identificano coerentemente le regioni spettrali legate alle bande di assorbimento N-H, O-H e C-H, in accordo con la composizione chimica attesa (differenze in proteine, grassi e acqua tra le specie animali).
- Validazione:** La performance sul test set indipendente confermata dalla confusion matrix dimostra che il modello generalizza adeguatamente a campioni non visti durante la calibrazione.

Note Metodologiche

- La divisione calibrazione/test è stata effettuata con campionamento stratificato (70/30) per mantenere la proporzione delle classi.
- La cross-validation Venetian Blind è stata scelta per garantire riproducibilità (a differenza del random subset).
- La matrice Y è codificata come dummy (one-hot) per adattare il problema di classificazione alla regressione PLS (PLS-DA).
- Il preprocessing Y consiste esclusivamente in mean centering.