

Analisi PLS Regression Farine Animali NIR

Regressione PLS / PLS-DA per la classificazione di farine animali (pollo, bovino, pesce) tramite spettroscopia NIR

Dataset	farineanimNIR.mat (84 campioni × 2001 wavenumbers)
Range spettrale	6000 – 4000 cm ⁻¹ (NIR)
Classi	Pollo, Bovino, Pesce
Metodo	PLS-DA (Partial Least Squares Discriminant Analysis)
Cross-Validation	Venetian Blind (15 splits, thickness = 3)
Software	MATLAB + PLS Toolbox (Eigenvector Research Inc.)

Indice

PCA Esplorativa

1. Score Plot PC1 vs PC2
2. Loading Plot
3. T^2 vs Q — Outlier Detection
4. Spettri NIR Originali

Selezione Numero LV

5. Scree Plot — Scelta Numero LV

Modello PLS Finale

7. T^2 vs Q (PLS)
8. Score Plot LV1 vs LV2
9. Y Predetto vs Y Misurato
10. Residui Cross-Validation
11. Leverage vs Residuals
12. Inner Relations

Importanza Variabili

13. PLS Weights
14. Coefficienti di Regressione
15. VIP Scores
16. Selectivity Ratio

Validazione

17. Test Set Prediction
18. Confusion Matrix
19. Spettri Preprocessati vs Originali

1. PCA Esplorativa — Score Plot (PC1 vs PC2)




Figura: 01_PCA_scores_PC1_PC2.png

Lo score plot della PCA esplorativa (con solo mean centering) mostra la proiezione dei campioni nel sotto-spazio a 2 componenti principali. **PC1** spiega tipicamente la quasi totalità della varianza (>99%) e cattura effetti fisici quali variazioni di *scattering* e spostamenti di baseline, che colpiscono uniformemente l'intero spettro NIR.

In questo grafico si osserva la distribuzione dei campioni colorati per classe (pollo, bovino, pesce). Le classi non sono ben separate lungo PC1, ciò conferma che la prima componente è dominata da variazioni fisiche piuttosto che chimiche, e indica la necessità di un preprocessing spettrale (es. derivate, SNV, MSC) per rimuovere questi effetti prima di costruire il modello PLS.

2. PCA Esplorativa — Loading Plot




Figura: 02_PCA_loadings.png

I loadings mostrano il contributo di ciascun wavenumber alle componenti principali.

Loading PC1 (blu): Un picco iniziale dopodiché un profilo abbastanza monotono, questo indica che PC1 cattura variazioni fisiche (scattering, baseline shift) che influenzano uniformemente lo spettro. Questo è coerente con il fatto che PC1 spiega una percentuale enorme della varianza.

Loading PC2 (rosso): Nonostante spieghi poca varianza, presenta picchi e valli ben definiti, indicatori di variazione chimica reale: le regioni con loadings elevati corrispondono a bande di assorbimento di gruppi funzionali come O-H ($\sim 5200 \text{ cm}^{-1}$), N-H ($\sim 4600 \text{ cm}^{-1}$) e C-H ($\sim 4300 \text{ cm}^{-1}$), legati a differenze nel contenuto di acqua, proteine e grassi tra le categorie.

3. PCA Esplorativa — T^2 vs Q (Outlier Detection)




Figura: 03_PCA_T2_vs_Q.png

Il grafico T^2 vs Q permette di identificare campioni anomali (outlier).

T^2 (Hotelling): Misura quanto un campione si discosta dal centro del modello nello spazio delle PC selezionate. Valori elevati indicano campioni con variazioni estreme *dentro* il modello.

Q (Residui): Misura quanto un campione non è spiegato dal modello. Valori elevati indicano campioni che il modello non riesce a descrivere bene (diversità strutturale).

Campioni con T^2 alto e Q basso sono spiegati dal modello ma sono estremi; campioni con T^2 basso e Q alto non sono ben descritti; campioni con entrambi alti sono i più critici. Questa analisi è fondamentale per decidere se escludere outlier prima di costruire il modello PLS. Notiamo infatti che qualche campione che non viene ben catturato dal modello o risulta essere un outlier è presente.

4. Spettri NIR Originali




Figura: 04_spettri_originali.png

A sinistra sono mostrati tutti gli spettri NIR originali, colorati per classe. Si possono osservare le differenze globali tra i gruppi e la sovrapposizione nelle regioni comuni.

A destra gli spettri medi per categoria evidenziano le differenze sistematiche. Le regioni di maggior interesse nel mid-NIR ($6000\text{--}4000\text{ cm}^{-1}$) includono:

- **$\sim 5200\text{ cm}^{-1}$** : Combinazione O-H (acqua)
- **$\sim 4600\text{ cm}^{-1}$** : Combinazione N-H (proteine)
- **$\sim 4300\text{ cm}^{-1}$** : Combinazione C-H (lipidi, carboidrati)

Le differenze tra gli spettri medi sono spesso sottili e mascherate da effetti di scattering, giustificando il preprocessing spettrale.

5. Scree Plot — RMSEC e RMSECV vs Numero LV




Figura: 05_scree_plot_LV.png

Lo scree plot confronta l'errore in calibrazione (RMSEC, blu) con l'errore in cross-validation (RMSECV, rosso) al variare del numero di LV, utilizzando il preprocessing scelto (SNV + Mean Centering).

Criterio di scelta del numero di LV: Si seleziona il numero di LV corrispondente al "gomito" della curva RMSECV, cioè il punto dopo il quale aggiungere ulteriori LV non produce un miglioramento significativo dell'errore di CV, o peggio, lo aumenta (overfitting).

SNV (Standard Normal Variate) corregge gli effetti di scattering moltiplicativo e additivo tipici degli spettri NIR, normalizzando ciascuno spettro per la propria media e deviazione standard. Dopo SNV, il **Mean Centering** centra i dati sull'origine, facilitando la decomposizione PLS.

7. Modello PLS — T^2 vs Q




Figura: 07_T2_vs_Q_PLS.png

Analoga al T^2 vs Q della PCA, ma calcolata sul modello PLS finale. Si verificano:

- **Accumulo intorno allo zero:** La maggior parte dei campioni si concentra a bassi valori di T^2 e Q , indicando che il modello li descrive bene.
- **Campioni con T^2 elevato ma Q basso:** Sono campioni estremi ma ben spiegati dal modello (variazioni chimiche reali, non errori).
- **Campioni con Q elevato:** Non ben descritti dal modello, possono indicare contaminazioni o errori sperimentali.

Le linee tratteggiate rosse indicano i limiti di confidenza al 95%. Campioni oltre entrambi i limiti sono potenziali outlier da investigare.

8. Score Plot PLS — LV1 vs LV2




Figura: 08_scores_LV1_LV2.png

Lo score plot nello spazio delle Latent Variables del PLS mostra come il modello separa le classi. A differenza della PCA, che massimizza la varianza di X, le LV del PLS massimizzano la covarianza tra X e Y, quindi la separazione tra classi dovrebbe essere migliore.

Dal grafico notiamo gruppi abbastanza separati, questo indica che il modello ha trovato pattern spettrali discriminanti tra le categorie. La posizione relativa dei cluster fornisce informazioni sulla somiglianza tra classi: categorie vicine hanno profili spettrali simili.

9. Y Misurato vs Y Predetto (per classe)




Figura: 09_01_Y_pred_vs_meas_Bovino.png

Per ciascuna classe (variabile dummy), il grafico confronta i valori misurati (0 o 1) con i valori predetti dal modello, sia in **calibrazione (fit)** che in **cross-validation**.

Pannello sinistro (Fit): Mostra la capacità del modello di riprodurre i dati di training.

Pannello destro (CV): Misura la capacità predittiva lasciando fuori campioni uno alla volta (o a gruppi).

11. Leverage vs Y Residuals




Figura: 11_leverage_vs_residuals.png

Il grafico Leverage vs Residui è uno strumento diagnostico per identificare campioni influenti.

Leverage (asse x): Misura quanto un campione influenza il modello. Campioni con leverage elevato hanno un peso sproporzionato nella costruzione del modello.

Notiamo esserci in questo caso alcuni campioni con leverage alto e altrettanto residui alti, questo significa che quei campioni influenzano molto il modello, ma non saranno ben predetti.

12. Inner Relations (T scores vs U scores per LV)




Figura: 12_inner_relations.png

Le inner relations mostrano la relazione tra X-scores (T) e Y-scores (U) per ogni Latent Variable. Nel modello PLS, la relazione $T \rightarrow U$ deve essere lineare.

- **Prime LV:** Mostrano una struttura lineare forte, indicando che catturano la maggior parte dell'informazione predittiva.
- **LV successive:** La struttura lineare si attenua, il contributo informativo diminuisce.

14. Coefficienti di Regressione PLS




Figura: 14_regression_coefficients.png

Nelle regioni NIR 4000-6000 cm^{-1} , i coefficienti di maggior modulo dovrebbero localizzarsi in corrispondenza delle bande di overtone **N-H** (proteine), **O-H** (acqua) e **C-H** (lipidi), che differenziano il contenuto nutritivo di pollo, bovino e pesce.

15. VIP Scores (Variable Importance in Projection)




Figura: 15_VIP_scores.png

Le regioni con VIP elevato identificano le bande spettrali più informative per la classificazione che in questo caso si collocano tra 4200-4300, 4900-4950, 5100-5300 e 5950-6000.

17. Validazione Test Set — Y Predetto vs Y Misurato

Il modello presenta un valore di R^2 di circa 0.88 sul test set, indicando una buona capacità predittiva su campioni mai visti prima. Il valore di RMSEP è simile a quello di RMSECV (0.32 vs 0.30), suggerendo che il modello generalizza bene senza overfitting.

18. Confusion Matrix — Calibrazione e Test Set




Figura: 18_confusion_matrix.png

Da questa matrice possiamo osservare l'accuratezza del modello nel train set e nel test set. Vediamo che vi è un solo elemento mal classificato (un campione di pesce predetto come pollo) nel test set, mentre in calibrazione tutti i campioni sono stati classificati correttamente. Questo conferma la buona performance del modello.

Conclusioni

L'analisi PLS-DA condotta sugli spettri NIR delle farine animali ha dimostrato l'efficacia della spettroscopia nel vicino infrarosso per la classificazione di campioni di diversa origine (pollo, bovino, pesce).