





Classificazione Chemometrica di Mosti d'Uva tramite Profilo Antocianico (HPLC)

Pipeline Algoritmica: Decomposizione PCA, Modellazione SIMCA e Discriminante PLS-DA

Dataset: 98 campioni
Input: 6 variabili (p)
Target: 5 classi (K)
Metadati: 2 annate

ARCHITETTURA DEI DATI



Input (X)

- 98 oggetti (mosti)
- 6 feature (variabili antocianiche)

Target Classi (y)

1. Ancellotta
2. Montepulciano
3. Lambrusco P.
4. Sangiovese
5. Nero d'Avola


Obiettivo

- Mappare $\mathbf{X} \rightarrow$ Classe
- Minimizzare errore di generalizzazione

PREPROCESSING: AUTOSCALING

$$Z_{ij} = \frac{X_{ij} - \bar{X}_j}{S_j}$$

Risultato: Media = 0,
Varianza = 1



ANALISI PCA

$$X = TP^T + E$$

Data Matrix [n x p]

Matrice di dati originali.

n: numero di osservazioni (oggetti), p: numero di variabili (feature).

Scores (Coordinate Latenti) [n x k]

Proiezioni delle osservazioni nello spazio latente a dimensionalità ridotta ($k < p$).

Coordinate delle nuove feature.

Loadings (Autovettori) [k x p]

Matrice trasposta dei pesi.

Definisce l'orientamento dei nuovi assi (componenti principali) nello spazio originale.
Collegamento tra variabili originali e latenti.


Residuals (Rumore) [n x p]

Matrice degli errori.


Rappresenta la parte dei dati non spiegata dalle k componenti principali (informazione persa).

SELEZIONE DIMENSIONALITÀ

Scree Plot




Cumulative Explained Variance



Analisi: PC1 + PC2 spiegano >80% della varianza totale.


Decisione algoritmica: Spazio latente a 2 dimensioni sufficiente per la visualizzazione.

Esplorazione dello Spazio Latente (Score Plot)




Clustering Spontaneo: La struttura chimica separa naturalmente i varietali senza supervisione.

Interpretazione delle Feature (Biplot)



Verifica dell'Ipotesi "Effetto Annata"


PCA Score Plot: PC1 vs PC2 (by Vintage)



Conclusione Statistica: **Varianza(Varietale) >> Varianza(Annata)**.
Il modello può essere addestrato su annate combinate.


Strategia di Classificazione Supervisionata

1. SIMCA (Class Modeling)



Definisce confini chiusi per ogni classe.
Riconosce "Non-Membri".

2. PLS-DA (Discriminant Analysis)




Definisce superfici di separazione.
Massimizza la covarianza.

Setup Sperimentale: Split 70% Training / 30% Test.

Metodo 1: SIMCA - Algoritmo



$$D = \sqrt{(T^2/T_{\text{lim}}^2)^2 + (Q/Q_{\text{lim}})^2}$$



- Modelli PCA Disgiunti (uno per varietale)
- Alpha = 0.05 (Livello di confidenza)



Alpha = 0.05 (Livello di confidenza)

SIMCA: Risultati e Confini di Classe



Training Accuracy: 95.7% | Test Accuracy: 93.1%. Alta specificità nel rigettare le altre classi.



Metodo 2: PLS-DA (Discriminant Analysis)





Ottimizzazione: Minimo errore di cross-validazione a 3 Variabili Latenti.

Training Accuracy: XX.X% | Test Accuracy: XX.X% | Alta specificità e robustezza nel modello.

Spazio Latente PLS e Feature Selection




Performance Predittiva PLS-DA (Test Set)




Accuratezza Test: 92.6%. Decisione rigida basata su $Y_{pred} > 0.5$.

Confronto Metodologico: SIMCA vs PLS-DA



SIMCA	Modellistico	Ottimo per Controllo Qualità (Autenticazione)
PLS-DA	Discriminante	Ottimo per Tracciabilità (Separazione)

Validazione dell'Applicability Domain



Analisi di Affidabilità: I campioni di test ricadono nel dominio chimico del training set ($h < h^*$). Le predizioni sono chimicamente valide e non estrapolate.