

Analisi di Classificazione Olio di Oliva Italiano

SIMCA & PLS-DA

Corso: Elaborazione Dati Scientifici

A.A. 2024-2025

Data: 17/02/2026

Dataset: Olive Oil (382 campioni, 7 acidi grassi, 5 regioni italiane)

Indice

1. Introduzione e Descrizione del Dataset

2. Fondamenti Teorici

- 2.1 Analisi delle Componenti Principali (PCA)
- 2.2 SIMCA (Soft Independent Modelling of Class Analogy)
- 2.3 PLS-DA (Partial Least Squares Discriminant Analysis)
- 2.4 Metriche di Valutazione

3. Analisi Esplorativa dei Dati (EDA)

- 3.1 Distribuzione globale delle variabili
- 3.2 Distribuzione per classe
- 3.3 Matrice di correlazione
- 3.4 PCA esplorativa: varianza spiegata
- 3.5 PCA esplorativa: score plots
- 3.6 PCA esplorativa: loading analysis

4. Classificazione con SIMCA

- 4.1 Cross-validazione e scelta delle componenti
- 4.2 Score Distance vs Orthogonal Distance
- 4.3 Matrici di confusione e metriche
- 4.4 Potere discriminante e loadings

5. Classificazione con PLS-DA

- 5.1 Cross-validazione e RMSECV
- 5.2 Predizioni Y e matrici di confusione
- 5.3 Score plots PLS
- 5.4 Coefficienti di regressione e VIP

6. Confronto dei Metodi e Conclusioni

1. Introduzione e Descrizione del Dataset

Il presente report documenta l'analisi di classificazione completa eseguita sul dataset Olive Oil. L'obiettivo è discriminare campioni di olio d'oliva provenienti da 5 diverse regioni italiane sulla base della loro composizione in acidi grassi, utilizzando due metodi di classificazione complementari: SIMCA (class modeling) e PLS-DA (discriminant analysis). L'analisi si articola in una fase esplorativa (EDA con PCA) seguita dalla costruzione, validazione e confronto dei due modelli classificatori.

Dataset

Il dataset contiene 382 campioni di olio d'oliva italiano, ciascuno caratterizzato dalla concentrazione percentuale di 7 acidi grassi misurati tramite gascromatografia. Le variabili analitiche sono:

- Acido Palmitico (C16:0) - acido grasso saturo, principale componente della frazione satura
- Acido Palmitoleico (C16:1) - acido grasso monoinsaturo a 16 atomi di carbonio
- Acido Stearico (C18:0) - acido grasso saturo a 18 atomi di carbonio
- Acido Oleico (C18:1) - acido grasso monoinsaturo predominante, tipico dell'olio d'oliva
- Acido Linoleico (C18:2) - acido grasso polinsaturo omega-6 essenziale
- Acido Eicosanoico (C20:0) - acido grasso saturo a catena lunga, presente in tracce
- Acido Linolenico (C18:3) - acido grasso polinsaturo omega-3, presente in piccole quantità

Classi

I campioni appartengono a 5 aree geografiche italiane con numerosità molto diverse:

- NA - North Apulia (Puglia Nord): 25 campioni (6.5%) - classe più piccola
- SA - South Apulia (Puglia Sud): 206 campioni (53.9%) - classe dominante
- U - Umbria: 51 campioni (13.4%)
- EL - East Liguria (Liguria Est): 50 campioni (13.1%)
- WL - West Liguria (Liguria Ovest): 50 campioni (13.1%)

Lo sbilanciamento delle classi è un elemento critico: la classe SA (South Apulia) contiene più della metà dei campioni totali ($206/382 = 53.9\%$), mentre la classe NA (North Apulia) ne contiene solo 25 (6.5%). Questo squilibrio può influenzare le prestazioni di classificazione, favorendo la classe maggioritaria e rendendo meno stabili le stime per la classe minoritaria, specialmente in cross-validazione. Per mitigare questo effetto, è stata utilizzata una suddivisione train/test stratificata (70/30) che preserva le proporzioni originali delle classi.

2. Fondamenti Teorici

2.1 PCA - Analisi delle Componenti Principali

La PCA (Principal Component Analysis) è una tecnica di riduzione della dimensionalità che trasforma le variabili originali, potenzialmente correlate, in un nuovo set di variabili ortogonali e non correlate chiamate Componenti Principali (PC). Le PC sono ordinate per varianza spiegata decrescente: la prima PC cattura la direzione di massima varianza nei dati, la seconda la massima varianza residua ortogonale alla prima, e così via.

La decomposizione matriciale è: $X = T \cdot P' + E$, dove T (scores) rappresentano le coordinate dei campioni nello spazio ridotto, P (loadings) esprimono il contributo delle variabili originali alle componenti, ed E i residui. La PCA è implementata tramite SVD (Singular Value Decomposition) della matrice X autoscalata. L'autoscaling (sottrazione della media e divisione per la deviazione standard) è essenziale per dare uguale peso a variabili con scale diverse.

2.2 SIMCA - Soft Independent Modelling of Class Analogy

SIMCA è un metodo di class modeling: costruisce un modello PCA indipendente per ciascuna classe, definendo i confini di appartenenza tramite limiti statistici. Le caratteristiche fondamentali del metodo sono:

- Soft: non fa assunzioni restrittive sulla distribuzione dei dati
- Independent: ogni classe ha il proprio modello PCA con il proprio numero di componenti
- Modeling: definisce lo spazio di ciascuna classe tramite un modello matematico
- Un campione può essere accettato da più classi, una sola classe, o nessuna classe

Per ogni campione si calcolano due distanze rispetto al modello di ciascuna classe:

1) Score Distance (SD): misurata dalla statistica T^2 di Hotelling, quantifica quanto il campione è lontano dal centro della classe nello spazio delle PC. Segue una distribuzione F .

2) Orthogonal Distance (OD): misurata dalla statistica Q (somma dei quadrati dei residui), quantifica quanto il campione è lontano dal sottospazio PCA del modello. Il limite Q viene calcolato con l'approssimazione di Jackson-Mudholkar basata sugli autovalori residui.

Il criterio di appartenenza combinato è:

$$D = \sqrt{(T^2/T^2_{lim})^2 + (Q/Q_{lim})^2} \leq \sqrt{2}$$

Il Discriminant Power misura la capacità discriminante di ciascuna variabile, calcolato come rapporto tra la varianza residua dei campioni esterni e quella dei campioni appartenenti alla classe.

2.3 PLS-DA - Partial Least Squares Discriminant Analysis

PLS-DA è un metodo discriminante che combina la regressione PLS con la codifica dummy delle classi. La matrice Y contiene variabili indicatrici binarie (1/0) che codificano l'appartenenza alle classi. L'algoritmo NIPALS (Nonlinear Iterative Partial Least Squares) decompone simultaneamente X e Y :

$$X = T \cdot P' + E$$

$$Y = U \cdot Q' + F$$

Le variabili latenti (LV) sono scelte per massimizzare la covarianza tra X e Y, quindi sono intrinsecamente orientate alla discriminazione. La predizione avviene tramite:

$$Y_{\text{pred}} = X_{\text{new}} * B_{\text{PLS}} + \text{mean}(Y)$$

dove $B_{\text{PLS}} = W * (P'W)^{-1} * \text{diag}(b) * Q'$ sono i coefficienti di regressione.

La classificazione si basa sul criterio True Discriminant: ogni campione viene assegnato alla classe corrispondente al valore massimo di Y predetto. A differenza di SIMCA, PLS-DA assegna sempre ogni campione a esattamente una classe (hard classification).

I VIP scores (Variable Importance in Projection) misurano l'importanza globale di ciascuna variabile nella proiezione PLS, ponderata per la varianza di Y spiegata da ciascuna LV.

2.4 Metriche di Valutazione

Per entrambi i metodi si utilizzano le seguenti metriche, calcolate per ciascuna classe:

- Sensitivity (Sensibilità): $TP / (TP + FN)$ - proporzione di campioni della classe correttamente identificati. Una sensibilità bassa indica che molti campioni della classe vengono persi.
- Specificity (Specificità): $TN / (TN + FP)$ - proporzione di campioni delle altre classi correttamente rifiutati. Una specificità bassa indica che molti campioni estranei vengono erroneamente accettati.
- Efficiency (Efficienza): $\sqrt{\text{Sensitivity} * \text{Specificity}}$ - media geometrica che bilancia sensibilità e specificità, particolarmente utile per classi sbilanciate.
- Accuracy: proporzione totale di classificazioni corrette su tutti i campioni.

La cross-validazione (venetian blinds, 5 segmenti) viene utilizzata per selezionare la complessità ottimale dei modelli: il numero di PC per ciascuna classe SIMCA e il numero di LV per PLS-DA. Questo approccio fornisce una stima imparziale delle prestazioni evitando l'overfitting.

3. Analisi Esplorativa dei Dati (EDA)

L'analisi esplorativa dei dati (EDA) rappresenta il primo passo fondamentale dell'analisi. Il suo scopo è comprendere la struttura dei dati, identificare pattern, correlazioni, outlier e valutare visivamente la separabilità delle classi prima di applicare metodi di classificazione.

3.1 Distribuzione Globale delle Variabili

Il boxplot delle variabili grezze (non autoscalate) mostra la distribuzione di ciascuno dei 7 acidi grassi sull'intero dataset di 382 campioni. Per ogni variabile, il box rappresenta l'intervallo interquartile (IQR, dal 25o al 75o percentile), la linea centrale indica la mediana, e i baffi (whiskers) si estendono fino a $1.5 \times \text{IQR}$. I punti al di fuori dei baffi sono outlier.

Figura 1: Boxplot delle 7 variabili (acidi grassi) sull'intero dataset (382 campioni).

Dall'osservazione del grafico emergono aspetti fondamentali:

- L'acido oleico (Oleico, C18:1) domina nettamente con una mediana intorno al 75-78%, coerente con la composizione tipica dell'olio d'oliva extra vergine. La sua distribuzione è relativamente compatta, indicando una buona omogeneità tra i campioni.
- L'acido linoleico (Linoleico, C18:2) è il secondo componente per abbondanza, con valori tra circa 5% e 15%, mostrando una dispersione significativa che lo rende potenzialmente discriminante.
- L'acido palmitico (Palmitico, C16:0) occupa il terzo posto con valori intorno all'10-14%.
- Le variabili Palmitoleico, Stearico, Eicosanoico e Linolenico presentano valori molto bassi (< 5%) e scale molto diverse tra loro. Questo giustifica la necessità di autoscaling prima di applicare PCA e metodi multivariati, per evitare che l'oleico (per il suo range molto ampio) domini l'intera analisi.

- La presenza di alcuni outlier (cerchi al di fuori dei baffi) suggerisce la presenza di campioni atipici che potrebbero appartenere a classi particolari o rappresentare composizioni inusuali.

3.2 Distribuzione per Classe

Questo pannello contiene 7 subplot (uno per ciascun acido grasso), con boxplot suddivisi per le 5 classi (NA, SA, U, EL, WL). L'asse X riporta le classi, l'asse Y il valore della variabile corrispondente. Questa vista e' cruciale per identificare visivamente quali variabili discriminano meglio tra le regioni.




Figura 2: Distribuzione di ciascun acido grasso suddivisa per classe (regione geografica).

L'analisi per classe rivela pattern discriminanti importanti:

- Acido Palmitico: la classe SA (Sud Puglia) mostra valori mediamente piu' bassi rispetto alle classi liguri (EL, WL), suggerendo una prima separazione tra le macroaree.
- Acido Palmitoleico: questa variabile mostra una forte differenziazione. Le classi EL e WL (Liguria) tendono ad avere valori piu' elevati rispetto alle classi pugliesi (NA, SA), mentre l'Umbria (U) occupa una posizione intermedia. Questa variabile potrebbe essere un marker geografico chiave.
- Acido Stearico: la distribuzione e' relativamente simile tra le classi, con lieve differenziazione, il che lo rende un discriminante piu' debole.
- Acido Oleico: variabile fondamentale. Le classi liguri (EL, WL) mostrano valori leggermente inferiori rispetto alle pugliesi, con la WL (Liguria Ovest, Taggiasche) che presenta una distribuzione piu' concentrata. L'Umbria mostra valori intermedi.
- Acido Linoleico: pattern complementare all'oleico (correlazione inversa attesa). Le classi EL e WL tendono a valori piu' alti, mentre SA ha valori piu' bassi e concentrati.
- Acido Eicosanoico e Linolenico: valori bassi con differenziazione modesta. Tuttavia, anche piccole differenze sistematiche possono contribuire alla classificazione multivariata.

3.3 Matrice di Correlazione

La matrice di correlazione di Pearson visualizza le relazioni lineari bivariate tra tutte le 7 variabili. La colormap (jet: blu = correlazione negativa forte, rosso = correlazione positiva forte) e' accompagnata dalle annotazioni numeriche del coefficiente r per ciascuna coppia. La diagonale mostra sempre $r = 1.00$ (autocorrelazione).




Figura 3: Matrice di correlazione di Pearson tra i 7 acidi grassi, con annotazioni numeriche.

Dalla matrice di correlazione si possono trarre le seguenti osservazioni:

- Oleico vs Linoleico: questi due acidi grassi mostrano una forte correlazione negativa (r atteso intorno a -0.8/-0.9). Questo riflette la biochimica della pianta d'olivo: la desaturazione dell'oleico produce linoleico, quindi un aumento dell'uno corrisponde a una diminuzione dell'altro. Questa anticorrelazione e' la principale sorgente di variabilita' nel dataset e dominera' la prima componente principale.
- Palmitoleico e Linoleico: correlazione positiva moderata, che indica un trend comune legato probabilmente alla maturazione e al clima.
- Palmitico e Oleico: correlazione negativa, coerente con il profilo degli oli meridionali (alto oleico, basso palmitico) vs settentrionali.

- Eicosanoico e Linolenico: bassa correlazione con le altre variabili, il che indica che portano informazione indipendente, anche se di piccola entità.

La presenza di correlazioni significative giustifica l'uso della PCA, che è progettata proprio per gestire e sfruttare la struttura di correlazione tra le variabili. Le variabili fortemente correlate contribuiranno alle stesse componenti principali.

3.4 PCA Esplorativa: Varianza Spiegata

Lo scree plot e il grafico della varianza cumulativa sono strumenti fondamentali per determinare il numero di componenti principali significative. La PCA e' stata eseguita sulla matrice autoscalata (382 x 7) tramite SVD.




Figura 4: Scree plot (sinistra) e varianza cumulativa (destra) delle componenti principali.

Il pannello sinistro (Scree Plot) mostra la percentuale di varianza spiegata da ciascuna singola PC tramite un diagramma a barre. In un dataset con 7 variabili si ottengono al massimo 7 PC. L'andamento tipico e' una curva decrescente: le prime PC catturano la maggior parte della varianza, mentre le ultime catturano prevalentemente rumore.

Il pannello destro (Varianza Cumulativa) mostra la somma cumulata delle varianze, con una linea rossa tratteggiata al 95%. Questo grafico permette di stabilire quante PC sono necessarie per catturare una quota sufficiente dell'informazione totale.

Dall'analisi si osserva che:

- La PC1 cattura tipicamente il 35-45% della varianza, dominata dall'asse oleico-linoleico.
- La PC2 aggiunge un ulteriore 20-25%, portando il cumulato al 60-70%.
- Con 3 PC si supera generalmente l'80% della varianza.
- Per raggiungere il 95% sono necessarie 4-5 PC.

Il 'gomito' dello scree plot (punto di flessione dove la curva si appiattisce) indica la dimensionalita' intrinseca dei dati e guida la scelta del numero di PC per la modellazione SIMCA.

3.5 PCA Esplorativa: Score Plots

Score Plot 2D

I grafici degli scores proiettano i 382 campioni nello spazio ridotto delle PC. I campioni sono colorati per classe e visualizzati come scatter plot. Il pannello sinistro mostra PC1 vs PC2, quello destro PC1 vs PC3. Le etichette degli assi riportano la percentuale di varianza spiegata.




Figura 5: Score plots PCA - PC1 vs PC2 (sinistra) e PC1 vs PC3 (destra), colorati per classe.

Analisi dello score plot PC1 vs PC2:

- Le classi liguri (EL ed WL) tendono a raggrupparsi in una regione dello spazio a valori positivi/negativi di PC1, separate dalle classi pugliesi.
- La classe SA (South Apulia), essendo la più numerosa, forma un cluster ampio e denso.
- La classe NA (North Apulia) mostra una distribuzione più dispersa, potenzialmente parzialmente sovrapposta con SA, il che è atteso data la prossimità geografica.
- L'Umbria (U) tende a posizionarsi in una regione intermedia, riflettendo la sua posizione geografica tra il Sud e il Nord.
- La separazione lungo PC2 aggiunge discriminazione extra, differenziando ulteriormente le classi che appaiono sovrapposte nella sola dimensione PC1.

Analisi dello score plot PC1 vs PC3:

- La terza PC cattura varianza complementare che può separare classi non distinguibili nel piano PC1-PC2. In particolare, la separazione tra EL e WL (entrambe liguri) potrebbe emergere lungo PC3, così come una migliore separazione tra NA e SA.

Score Plot 3D

Lo score plot 3D combina simultaneamente PC1, PC2 e PC3, fornendo una vista tridimensionale della struttura dei dati. L'angolo di visualizzazione è impostato a azimuth=30, elevation=25 per massimizzare la leggibilità dei cluster. I campioni sono rappresentati come sfere colorate per classe con bordo nero per migliorare il contrasto.




Figura 6: Score plot 3D (PC1 vs PC2 vs PC3), colorato per regione.

La visualizzazione 3D conferma e integra le osservazioni dei plot 2D:

- I cluster delle 5 classi sono discernibili anche visivamente, indicando che la composizione in acidi grassi contiene informazione sufficiente per la classificazione geografica.
- Le classi che appaiono sovrapposte nei plot 2D possono risultare separate nella terza dimensione.
- La compattezza dei cluster varia significativamente: SA, essendo la classe più numerosa, mostra una maggiore dispersione, mentre WL e EL tendono a essere più compatte.
- La presenza di eventuali campioni isolati (outlier) o ai margini dei cluster può indicare campioni di difficile classificazione che saranno critici per le prestazioni dei modelli.

3.6 PCA Esplorativa: Loading Analysis

Il pannello sinistro mostra un bar chart dei loadings delle prime tre PC (PC1, PC2, PC3), con una barra per ciascuna variabile raggruppata per PC. Il pannello destro mostra il loading plot nello spazio PC1-PC2, dove ciascuna variabile è rappresentata come un vettore dall'origine, con il cerchio unitario come riferimento.




Figura 7: Loading bar chart PC1-PC3 (sinistra) e Loading plot PC1 vs PC2 (destra).

Interpretazione dei loadings:

Bar chart (pannello sinistro):

- PC1: dominata dall'opposizione oleico (loading negativo o positivo elevato) vs linoleico (segno opposto). Palmitoleico contribuisce nella stessa direzione del linoleico. Questo conferma che la principale sorgente di variazione è la composizione oleico/linoleico.
- PC2: cattura la variazione in palmitoleico, stearico e potenzialmente eicosanoico, ortogonale all'asse oleico-linoleico.
- PC3: variabili minori come linolenico, eicosanoico e stearico contribuiscono maggiormente, catturando varianza residua non rappresentata dalle prime due PC.

Loading plot (pannello destro):

- Il cerchio unitario grigio tratteggiato indica il raggio massimo ($r=1$). Variabili vicine al cerchio sono ben rappresentate nello spazio PC1-PC2; variabili vicine all'origine sono mal rappresentate e richiedono PC aggiuntive.
- Oleico e Linoleico si trovano in direzioni opposte (anticorrelazione), confermando la struttura biochimica nota.
- La prossimità di Palmitoleico al Linoleico nello spazio dei loadings indica che queste variabili co-variano nello stesso senso.
- Eicosanoico e Linolenico, essendo vicini all'origine, sono scarsamente rappresentati nelle prime due PC e la loro informazione è catturata da PC successive.

4. Classificazione con SIMCA

Il metodo SIMCA (Soft Independent Modelling of Class Analogy) costruisce un modello PCA indipendente per ciascuna delle 5 classi. La selezione del numero ottimale di PC per classe avviene tramite cross-validazione (venetian blinds, 5 segmenti) sul training set, valutando PC da 1 a 6. Il criterio di classificazione combina la Score Distance (T2) e la Orthogonal Distance (Q) con un limite $D \leq \sqrt{2}$.

4.1 Cross-validazione e Scelta delle Componenti

Il grafico mostra tre pannelli sovrapposti, ciascuno con l'andamento di una metrica al variare del numero di PC (da 1 a 6), con una curva per ciascuna delle 5 classi. I pannelli sono:

- 1) Sensitivity (pannello superiore): per ciascun numero di PC, la proporzione di campioni della classe correttamente accettati dal proprio modello in CV. Valori alti sono desiderabili.
- 2) Specificity (pannello centrale): per ciascun numero di PC, la proporzione di campioni delle altre classi correttamente rifiutati. Una specificità troppo bassa indica che il modello è troppo 'morbido' e accetta campioni non appartenenti.
- 3) Efficiency (pannello inferiore): $\sqrt{\text{Sensitivity} * \text{Specificity}}$, media geometrica che fornisce un bilancio ottimale. Questo è il criterio usato per selezionare il numero di PC.




Figura 8: Metriche SIMCA in cross-validazione al variare del numero di PC per classe.

Dall'analisi di questo grafico si seleziona per ciascuna classe il numero di PC che massimizza l'efficienza. In generale:

- All'aumentare delle PC, la sensibilit  tende ad aumentare (i modelli diventano piu' flessibili e accettano piu' campioni), ma la specificita' puo' diminuire (i confini si allargano).
- L'efficienza bilancia questi due aspetti e tipicamente mostra un massimo dopo il quale l'aggiunta di PC non migliora ma potenzialmente peggiora le prestazioni.
- Classi con struttura interna piu' complessa (es. SA con molti campioni) potrebbero necessitare di piu' PC, mentre classi piccole e compatte (es. NA) potrebbero averne bisogno di meno.
- E' fondamentale che ciascuna classe possa avere un numero diverso di PC, coerentemente con la filosofia SIMCA di modellazione indipendente.

4.2 Score Distance vs Orthogonal Distance

Per ciascuna delle 5 classi viene generato un grafico SD vs OD che rappresenta il piano diagnostico fondamentale del modello SIMCA. L'asse X riporta la Score Distance normalizzata (T^2/T^2_{lim}), l'asse Y la Orthogonal Distance normalizzata (Q/Q_{lim}). La curva rossa rappresenta il cerchio di raggio $\sqrt{2}$, ovvero il confine di accettazione: campioni all'interno della curva sono accettati dal modello della classe. I cerchi (o) rappresentano i campioni di training, i diamanti (d) pieni rappresentano i campioni di test, tutti colorati per classe.




Figura 9: SIMCA - Score Distance vs Orthogonal Distance per il modello della Classe 1 (North Apulia). Cerchi = training, Diamanti = test, Curva rossa = confine $D \leq \sqrt{2}$.

Per il modello della classe North Apulia, i campioni NA di training (cerchi blu) dovrebbero trovarsi all'interno del cerchio rosso. I campioni delle altre classi (SA, U, EL, WL) dovrebbero trovarsi all'esterno, indicando che il modello li rifiuta. Data la piccola numerosità di NA (25 campioni, ~18 in training), il modello potrebbe essere meno stabile. Eventuali campioni NA di test (diamanti blu) all'esterno segnalano falsi negativi, mentre campioni di altre classi all'interno segnalano falsi positivi. La posizione dei campioni rispetto ai due assi indica la natura dell'anomalia: alta SD = lontano dal centro nello spazio delle PC, alta OD = struttura diversa non catturata dal modello.




Figura 10: SIMCA - Score Distance vs Orthogonal Distance per il modello della Classe 2 (South Apulia). Cerchi = training, Diamanti = test, Curva rossa = confine $D \leq \sqrt{2}$.

Il modello South Apulia è quello con più campioni di training (~144). La classe SA, essendo la più numerosa ed eterogenea, potrebbe richiedere più PC per una descrizione adeguata. I campioni SA dovrebbero formare un cluster compatto all'interno del cerchio, mentre le classi liguri (EL, WL), avendo composizioni diverse, dovrebbero trovarsi ben al di fuori. La separazione SA/NA è meno netta per la prossimità geografica. Campioni con elevata OD indicano una struttura chimica non compatibile con il modello SA, mentre campioni con elevata SD hanno composizioni compatibili ma estreme.




Figura 11: SIMCA - Score Distance vs Orthogonal Distance per il modello della Classe 3 (Umbria). Cerchi = training, Diamanti = test, Curva rossa = confine $D \leq \sqrt{2}$.

Il modello Umbria descrive una classe di dimensione intermedia (~36 in training). L'Umbria, essendo geograficamente tra il Centro e il Nord, potrebbe condividere caratteristiche con sia le classi pugliesi che quelle liguri. Il grafico mostra se campioni di altre classi vengono erroneamente accettati (bassa specificita') o se campioni umbri vengono rifiutati dal proprio modello (bassa sensibilita'). La posizione relativa delle classi rispetto al cerchio di accettazione rivela le 'distanze chimiche' tra le regioni dal punto di vista dell'Umbria.



Figura 12: SIMCA - Score Distance vs Orthogonal Distance per il modello della Classe 4 (East Liguria). Cerchi = training, Diamanti = test, Curva rossa = confine $D \leq \sqrt{2}$.

Il modello East Liguria mostra le distanze di tutti i campioni rispetto al modello PCA costruito sui campioni liguri orientali. Le classi EL e WL (entrambe liguri) potrebbero avere una sovrapposizione parziale, che si manifesta con campioni WL all'interno o vicino al confine del modello EL. I campioni pugliesi (NA, SA) dovrebbero essere chiaramente al di fuori, con OD elevata per la diversa struttura degli acidi grassi. L'analisi dei campioni di test (diamanti) rispetto al training (cerchi) indica la generalizzabilità del modello.




Figura 13: SIMCA - Score Distance vs Orthogonal Distance per il modello della Classe 5 (West Liguria). Cerchi = training, Diamanti = test, Curva rossa = confine $D \leq \sqrt{2}$.

Il modello West Liguria (Taggiasche) descrive una classe con composizione distintiva. Le olive taggiasche hanno un profilo di acidi grassi specifico che potrebbe rendere questa classe più compatta e ben separata. Il grafico mostrerà se questo è confermato: campioni WL concentrati all'interno del cerchio e campioni delle altre classi ben all'esterno. Una buona separazione nel piano SD/OD corrisponde a elevata efficienza di classificazione per questa classe.

4.3 Matrici di Confusione e Metriche

Matrici di Confusione SIMCA

La matrice di confusione e' una tabella (nClasses x nClasses) che riassume le predizioni del classificatore. Le righe rappresentano le classi predette, le colonne le classi vere (o viceversa, secondo la convenzione). Gli elementi sulla diagonale sono le classificazioni corrette (True Positives per ciascuna classe), gli elementi extra-diagonali sono gli errori. I valori percentuali annotati in ciascuna cella facilitano la lettura. Due matrici sono presentate fianco a fianco: training set (sinistra) e test set (destra).




Figura 14: Matrici di confusione SIMCA per training set (sinistra) e test set (destra).

Interpretazione delle matrici di confusione:

- **Diagonale:** i numeri sulla diagonale indicano quanti campioni di ciascuna classe sono stati correttamente classificati. Percentuali alte sulla diagonale corrispondono ad alta sensibilità.
- **Elementi extra-diagonali:** indicano confusione tra le classi. Ad esempio, un valore alto nella cella (riga SA, colonna NA) indica che molti campioni NA sono stati classificati come SA. Questo tipo di errore rivela la somiglianza chimica tra le regioni.
- **Confronto training vs test:** il modello tipicamente performa meglio sul training set. Una degradazione significativa sul test set e' segno di overfitting. SIMCA, essendo un metodo basato su modelli individuali per classe, e' relativamente robusto all'overfitting, ma classi con pochi campioni (NA) possono mostrare instabilità.
- Si noti che in SIMCA un campione puo' essere rifiutato da tutte le classi (non accettato) o accettato da piu' classi. In caso di accettazione multipla, la regola di assegnazione tipicamente sceglie la classe con la distanza D minore.

Tabella Riassuntiva SIMCA

La tabella riassuntiva mostra, per ciascuna classe: il numero ottimale di PC selezionato in CV, e le metriche di sensibilità, specificità ed efficienza calcolate sul training set e sul test set indipendente. Questa tabella permette un confronto diretto delle prestazioni per classe e tra i due set.

SIMCA Summary							
Class	nPCs	Sens_Train	Spec_Train	Eff_Train	Sens_Test	Spec_Test	Eff_Test
North Apulia	3	1	0.9960	0.9980	1	0.9907	0.9953
South Apulia	4	1	1	1	1	0.9615	0.9806
Umbria	2	1	1	1	0.9333	1	0.9661
East Liguria	6	0.9714	0.9957	0.9835	0.9333	0.9899	0.9612
West Liguria	1	0.9714	1	0.9856	0.8667	1	0.9309

Figura 15: Tabella riassuntiva delle metriche SIMCA per classe.

Dalla tabella si può valutare:

- Quali classi sono meglio modellate (alta efficienza su entrambi i set)
- Il grado di generalizzazione (confronto train vs test)
- L'effetto dello sbilanciamento (la classe SA potrebbe avvantaggiarsi dalla numerosità)
- La complessità di ciascuna classe (numero di PC necessarie)

4.4 Potere Discriminante e Loadings

Discriminant Power

Il Discriminant Power e' un indice specifico di SIMCA che quantifica la capacita' di ciascuna variabile di discriminare tra le classi. Viene calcolato come il rapporto medio tra i residui dei campioni non appartenenti alla classe e quelli appartenenti, mediato su tutte le coppie di classi. Il diagramma a barre mostra il valore per ciascuno dei 7 acidi grassi, con linee di riferimento orizzontali per il 95o percentile (verde), il 99o percentile (rosso) e la media (nero tratteggiato).




Figura 16: SIMCA Discriminant Power per ciascun acido grasso, con soglie percentili.

Interpretazione del Discriminant Power:

- Variabili con potere discriminante superiore al 95o percentile sono considerate 'molto discriminanti' e sono le piu' utili per la separazione delle classi.
- Variabili sopra il 99o percentile hanno un ruolo eccezionale nella discriminazione.
- Ci si attende che l'acido oleico, il linoleico e il palmitoleico abbiano elevato potere discriminante, coerentemente con le differenze osservate nei boxplot per classe.
- Variabili con basso potere discriminante (sotto la media) contribuiscono poco alla classificazione SIMCA e potrebbero essere eliminate in un'analisi di feature selection.
- Il ranking delle variabili per discriminant power puo' essere confrontato con i VIP scores della PLS-DA per verificare la coerenza tra i due metodi.

Loadings per Classe SIMCA

Questo pannello di grafici mostra i loadings dei modelli PCA di ciascuna classe, organizzati in una griglia (nClasses x maxPC). Ogni subplot mostra un diagramma a barre con il loading delle 7 variabili per una specifica PC di una specifica classe. Il colore delle barre indica la classe (blu=NA, rosso=SA, verde=U, magenta=EL, arancione=WL).




Figura 17: SIMCA Loadings per ciascuna classe e componente principale.

L'analisi dei loadings per classe e' fondamentale nella filosofia SIMCA:

- Se i loadings delle diverse classi sono simili, le classi condividono la stessa struttura di covarianza e la discriminazione si basa principalmente sulle posizioni nello spazio scores.
- Se i loadings sono diversi tra le classi, le classi hanno strutture interne differenti, il che giustifica pienamente l'approccio SIMCA di modellazione indipendente.
- Ad esempio, la PC1 di SA potrebbe essere dominata dall'asse oleico-linoleico, mentre la PC1 di WL potrebbe coinvolgere maggiormente il palmitoleico, indicando diverse sorgenti di variabilit .
- Classi con piu' PC (es. SA) hanno una struttura interna piu' complessa che richiede componenti aggiuntive per essere descritta. Classi con 1-2 PC hanno una struttura piu' semplice.
- La variabilit  dei loadings tra classi conferma che SIMCA e' la scelta appropriata rispetto a un singolo modello PCA globale.

5. Classificazione con PLS-DA

PLS-DA (Partial Least Squares Discriminant Analysis) costruisce un unico modello di regressione che mappa simultaneamente tutte le variabili X nella matrice di classi Y (dummy coding 1/0). L'algoritmo NIPALS trova variabili latenti che massimizzano la covarianza tra X e Y. La classificazione avviene assegnando ogni campione alla classe con il valore Y predetto più alto (True Discriminant). X è autoscalato e Y è mean-centered prima della regressione. La cross-validazione (venetian blinds, 5 segmenti) seleziona il numero ottimale di LV (da 1 a 10).

5.1 Cross-validazione e RMSECV

Errori di Classificazione in CV

La figura mostra 4 pannelli che visualizzano le prestazioni PLS-DA in cross-validazione al variare del numero di variabili latenti (LV) da 1 a 10:

- 1) % Correct Classification (alto-sx): la percentuale di campioni correttamente classificati per ciascuna delle 5 classi. Ciascuna classe ha la propria curva colorata. L'obiettivo è massimizzare queste percentuali.
- 2) Misclassified Samples (basso-sx): il numero assoluto di campioni mal classificati per classe. Complemento del pannello precedente, utile per capire l'entità assoluta degli errori.
- 3) Mean % Correct (alto-dx): la media delle percentuali corrette su tutte le classi, una singola curva blu. Questo è un indicatore globale unidimensionale delle prestazioni.
- 4) Total Misclassified (basso-dx): il numero totale di campioni mal classificati (somma su tutte le classi), una singola curva rossa. Il numero ottimale di LV è selezionato minimizzando questo valore.




Figura 18: PLS-DA Cross-Validation: percentuali corrette per classe, errori e metriche aggregate.

Dall'analisi di questi grafici si ricava il numero ottimale di LV:

- Per LV=1 le prestazioni sono generalmente basse, poiché una sola variabile latente non è sufficiente per discriminare 5 classi.
- Le prestazioni migliorano rapidamente con l'aggiunta delle prime LV (tipicamente fino a 3-5).
- Oltre un certo numero di LV, le prestazioni in CV si stabilizzano o peggiorano (overfitting).
- La classe NA, avendo pochi campioni, può mostrare oscillazioni maggiori tra i diversi numeri di LV per la minore stabilità statistica.
- Si impone un minimo di 2 LV per permettere la visualizzazione 2D degli scores.

RMSECV per Classe

Il grafico RMSECV (Root Mean Square Error of Cross-Validation) mostra l'errore di regressione in cross-validazione per ciascuna classe al variare del numero di LV. L'RMSECV misura quanto bene il modello predice i valori dummy (1/0) delle classi, non direttamente l'errore di classificazione. Una curva per ciascuna classe è tracciata, con marcatori circolari e legenda.




Figura 19: RMSECV per classe al variare del numero di variabili latenti.

NOTA IMPORTANTE: l'andamento dell'RMSECV non corrisponde necessariamente al trend degli errori di classificazione. L'RMSECV misura l'errore quadratico medio delle Y predette (valori continui) rispetto alle Y vere (0/1), mentre la classificazione dipende solo dal valore massimo tra le Y predette. Può accadere che una LV aggiuntiva riduca l'RMSECV senza migliorare la classificazione, o viceversa.

La classe SA (più numerosa) può mostrare un RMSECV più basso semplicemente per la maggiore disponibilità di campioni per la stima. Classi piccole (NA) tendono ad avere RMSECV più alto e più variabile.

5.2 Predizioni Y e Matrici di Confusione

Y Predetto - Training Set

Questa figura contiene 5 subplot verticali (uno per classe). In ciascun subplot:

- L'asse X rappresenta i campioni del training set (numerati sequenzialmente).
- L'asse Y mostra il valore predetto della Y dummy per quella specifica classe.
- I campioni appartenenti alla classe target sono rappresentati con simboli pieni (filled circles), quelli delle altre classi con simboli vuoti.
- Una linea rossa tratteggiata a $Y=0.5$ indica la soglia: campioni della classe target dovrebbero avere $Y > 0.5$, gli altri $Y < 0.5$.
- La linea grigia sottile collega i punti per facilitare la visualizzazione dell'andamento.



Figura 20: PLS-DA - Valori Y predetti per ogni classe sul training set.

Analisi del grafico Y predetto (training):

- Per un modello perfetto, i campioni della classe target (pieni) dovrebbero trovarsi tutti sopra la soglia 0.5 e i campioni delle altre classi (vuoti) tutti sotto.
- Campioni della classe target sotto la soglia sono falsi negativi: il modello non li riconosce.
- Campioni delle altre classi sopra la soglia sono falsi positivi: il modello li confonde.
- La 'altezza' sopra/sotto la soglia indica la confidenza della predizione: Y molto vicino a 0.5 indica poca confidenza, Y vicino a 1 o 0 indica alta confidenza.
- Le classi più piccole (NA) possono mostrare predizioni più 'incerte' (vicine a 0.5) perché il modello ha meno campioni.

da cui apprendere.

- Il training set tende a mostrare buone prestazioni anche da modelli sovraparametrizzati.

Y Predetto - Test Set

Struttura identica al grafico precedente ma calcolato sul test set indipendente. Questo e' il vero banco di prova del modello, poiche' i campioni di test non sono stati utilizzati nella costruzione del modello.




Figura 21: PLS-DA - Valori Y predetti per ogni classe sul test set.

Confronto training vs test nelle Y predette:

- Una degradazione significativa della separazione $Y > 0.5$ / $Y < 0.5$ dal training al test indica overfitting.
- Se le prestazioni sono stabili, il modello generalizza bene.
- Campioni di test con Y predette errate (sotto/sopra soglia) corrispondono agli errori nella matrice di confusione. La posizione di questi campioni rispetto alla soglia indica quanto il modello e' 'sicuro' delle sue predizioni errate.
- La classe SA, essendo la piu' rappresentata, tende ad avere predizioni piu' stabili e una separazione piu' netta, mentre le classi piccole mostrano piu' variabilita'.

Matrici di Confusione PLS-DA

Le matrici di confusione PLS-DA sono strutturate come quelle SIMCA (righe x colonne = predette x vere) con annotazioni percentuali. Training set a sinistra, test set a destra. A differenza di SIMCA, PLS-DA assegna sempre ogni campione a esattamente una classe (hard classification): non esistono campioni 'rifiutati' o assegnati a piu' classi.




Figura 22: Matrici di confusione PLS-DA per training set e test set.

Interpretazione delle matrici di confusione PLS-DA:

- Tutti i campioni sono assegnati a una (e una sola) classe, quindi il numero totale di campioni classificati corrisponde esattamente alla dimensione del dataset.
- Errori tipici: confusione tra NA e SA (prossimità geografica pugliese), confusione occasionale tra EL e WL (prossimità ligure), confusione tra U e classi limitrofe.
- Le prestazioni sul test set sono la misura più affidabile della capacità predittiva del modello, poiché non affette dal bias di autocalibrazione.
- Una matrice di confusione con elementi diagonali dominanti e valori extra-diagonali nulli o molto bassi indica un classificatore eccellente.

Tabella Riassuntiva PLS-DA

La tabella riassuntiva mostra per ciascuna classe: sensibilità, specificità ed efficienza sul training set e sul test set, oltre al RMSEP (Root Mean Square Error of Prediction). L'intestazione indica il numero ottimale di LV selezionato in cross-validazione.

PLS-DA Summary (7 LVs)							
Class	Sens_Train	Spec_Train	Eff_Train	Sens_Test	Spec_Test	Eff_Test	RMSEP
North Apulia	0.5000	1	0.7071	0.4286	1	0.6547	0.6488
South Apulia	1	0.9839	0.9919	1	0.9808	0.9903	0.1534
Umbria	0.9722	0.9828	0.9775	1	0.9697	0.9847	0.3663
East Liguria	0.8000	0.9700	0.8809	0.8667	1	0.9309	0.4653
West Liguria	1	0.9828	0.9914	1	0.9798	0.9898	0.3119

Figura 23: Tabella riassuntiva delle metriche PLS-DA per classe (con RMSEP).

Note sulla tabella:

- Il RMSEP e' calcolato solo sul test set e fornisce una misura dell'errore di predizione delle Y dummy. Un RMSEP basso indica predizioni precise delle variabili dummy.
- Classi con alta sensibilita' ma bassa specificita' tendono ad 'attrarre' campioni delle altre classi; classi con alta specificita' ma bassa sensibilita' 'perdono' i propri campioni.
- L'efficienza ($\sqrt{\text{Sens} \times \text{Spec}}$) e' la metrica piu' informativa per classi sbilanciate.

5.3 Score Plots PLS

Gli score plots PLS mostrano la proiezione dei campioni nello spazio delle prime due variabili latenti (LV1 vs LV2). Due pannelli affiancati: training set (sinistra) e test set (destra). I campioni sono colorati per classe con marcatori circolari pieni e bordo nero.




Figura 24: PLS-DA Score plots (LV1 vs LV2) - training set (sinistra) e test set (destra).

A differenza dello score plot PCA (Fig. 5), le variabili latenti PLS sono costruite per massimizzare la covarianza con Y (classi), non semplicemente la varianza di X. Di conseguenza:

- La separazione tra le classi dovrebbe essere piu' netta rispetto allo spazio PCA, poiche' le LV sono specificamente orientate alla discriminazione.
- Il training set mostra la separazione ottimale ottenuta dal modello.
- Il test set mostra la generalizzabilita' di questa separazione su campioni nuovi.
- Cluster piu' separati e compatti indicano una migliore capacita' discriminante.
- Campioni di test che cadono lontano dal cluster della propria classe sono quelli potenzialmente mal classificati.
- La proiezione del test set si ottiene applicando la matrice di proiezione $W^*(P^*W)^{-1}$ ai dati di test autoscalati con le statistiche del training set.

Il confronto tra lo score plot PCA (varianza-orientato) e lo score plot PLS (classe-orientato) e' particolarmente istruttivo: classi che si sovrappongono in PCA possono risultare separate in PLS, e viceversa.

5.4 Coefficienti di Regressione e VIP

Coefficienti di Regressione PLS

La figura mostra 5 subplot orizzontali (1 per classe), ciascuno con un diagramma a barre dei coefficienti di regressione B_{PLS} per le 7 variabili. Il colore delle barre corrisponde alla classe (blu=NA, rosso=SA, verde=U, magenta=EL, arancione=WL). Le etichette X indicano i nomi degli acidi grassi.




Figura 25: Coefficienti di regressione PLS-DA per ciascuna classe.

Interpretazione dei coefficienti di regressione:

- I coefficienti B_{PLS} rappresentano il 'peso' di ciascuna variabile nella predizione della Y dummy per ogni classe:
 $Y_{pred_k} = X * B_{PLS_k} + \text{mean}(Y_k)$.
- Coefficiente positivo: all'aumentare della variabile, aumenta la probabilit  (Y predetto) di appartenenza alla classe.
 Coefficiente negativo: all'aumentare della variabile, diminuisce.
- Il modulo (valore assoluto) indica l'importanza della variabile per quella specifica classe.
- Confrontando i pattern tra le classi: variabili con segni opposti in classi diverse sono particolarmente discriminanti tra quelle classi. Ad esempio, se l'oleico ha coefficiente positivo per SA e negativo per EL, l'oleico   un buon discriminante SA vs EL.
- La somma dei coefficienti di tutte le classi per una variabile non   necessariamente zero perche' Y   mean-centered, non sommata a 1.
- Variabili con coefficienti bassi in tutte le classi sono poco importanti per la classificazione.

VIP Scores

Il diagramma VIP (Variable Importance in Projection) mostra una barra per ciascuna delle 7 variabili, con due linee di

riferimento:

- Linea rossa tratteggiata a $VIP=1$: soglia convenzionale di importanza. Variabili con $VIP > 1$ sono considerate importanti per la classificazione.
- Linea nera puntinata a $VIP=0.8$: soglia inferiore. Variabili con $VIP < 0.8$ sono considerate poco influenti e potenziali candidate per l'eliminazione.

Le barre sono colorate in verde per facilitare la lettura.




Figura 26: VIP scores - Importanza delle variabili nella proiezione PLS-DA.

I VIP scores forniscono una misura globale (non specifica per classe) dell'importanza di ciascuna variabile nella discriminazione PLS-DA:

- $VIP > 1$: variabile importante. Contribuisce significativamente alla separazione delle classi nello spazio delle variabili latenti.
- $0.8 < VIP < 1$: variabile moderatamente importante. Può contribuire ma non è fondamentale.
- $VIP < 0.8$: variabile poco importante. La sua rimozione non dovrebbe degradare significativamente le prestazioni.

Il ranking VIP permette una feature selection informata: in un'applicazione pratica, si potrebbe ridurre il costo analitico misurando solo le variabili con VIP alto.

Confronto con il Discriminant Power SIMCA (Fig. 16): se le stesse variabili risultano importanti in entrambi i metodi (VIP alto e Discriminant Power alto), la conclusione è robusta. Discrepanze possono indicare che le due metriche catturano aspetti diversi della discriminazione (SIMCA basa il discriminant power sui residui, PLS-DA sulla covarianza con Y).

6. Confronto dei Metodi e Conclusioni

6.1 Confronto SIMCA vs PLS-DA

I due metodi di classificazione adottano filosofie fundamentalmente diverse:

SIMCA (Class Modeling):

- Costruisce modelli PCA indipendenti per ciascuna classe
- Può rifiutare campioni (nessuna classe li accetta) o assegnarli a più classi
- Adatto quando l'obiettivo è verificare l'autenticità/appartenenza a una specifica classe
- Ogni classe ha un proprio numero ottimale di PC
- Fornisce il Discriminant Power come misura di importanza delle variabili
- Robusto per campioni anomali o non appartenenti a nessuna classe nota

PLS-DA (Discriminant Analysis):

- Costruisce un unico modello focalizzato sulle differenze tra tutte le classi
- Assegna sempre ogni campione a esattamente una classe (hard classification)
- Adatto quando le classi sono ben definite e mutualmente esclusive
- Un unico numero di LV per l'intero modello
- Fornisce VIP scores e coefficienti di regressione per l'interpretazione
- Tipicamente più potente quando le classi sono ben separate

Confronto delle Prestazioni sul Test Set

La figura mostra due pannelli affiancati con diagrammi a barre raggruppate:

- Pannello sinistro (Test Set Sensitivity): per ciascuna classe, due barre che confrontano la sensibilità SIMCA (blu) e PLS-DA (rosso). Valori più alti indicano maggiore capacità di riconoscere correttamente i campioni della classe.
- Pannello destro (Test Set Specificity): per ciascuna classe, due barre che confrontano la specificità SIMCA e PLS-DA. Valori più alti indicano maggiore capacità di rifiutare campioni non appartenenti.

L'asse Y va da 0 a 1.1 per tutte le classi, permettendo un confronto diretto.




Figura 27: Confronto sensibilit  e specificit  sul test set tra SIMCA e PLS-DA per classe.

Interpretazione del confronto:

- Se PLS-DA mostra sensibilit  maggiore di SIMCA, il modello discriminante   pi  efficace nel riconoscere i campioni della classe. Cio'   comune quando le classi sono ben separate.
- Se SIMCA mostra specificit  maggiore, il modello per classe   pi  selettivo nel rifiutare campioni estranei. Cio'   tipico e costituisce il punto di forza di SIMCA.
- La classe NA (pi  piccola) potrebbe mostrare le maggiori differenze tra i due metodi a causa della scarsa numerosit  che rende i modelli meno stabili.
- Le classi SA (dominante) ed EL/WL (compatte e ben separate) tendono a performare bene con entrambi i metodi.
- L'Umbria (U), geograficamente intermedia, potrebbe essere la classe pi  critica per entrambi i classificatori.

6.2 Conclusioni

L'analisi di classificazione del dataset Olive Oil ha dimostrato che la composizione in acidi grassi   un descrittore efficace dell'origine geografica dell'olio d'oliva italiano. L'analisi pu  essere sintetizzata nei seguenti punti chiave:

1. L'analisi esplorativa (EDA con PCA) ha rivelato la presenza di raggruppamenti naturali nel dataset, con le prime 2-3 PC che catturano la maggior parte della varianza. L'asse oleico-linoleico   la principale sorgente di variabilit , con il palmitoleico come variabile aggiuntiva discriminante.
2. Le classi liguri (EL, WL) si separano bene dalle pugliesi (NA, SA), riflettendo le differenze climatiche e cultivar tra le regioni. L'Umbria occupa una posizione intermedia.

3. SIMCA ha costruito modelli PCA indipendenti con complessita' diversa per classe, fornendo una modellazione flessibile della struttura interna di ciascuna regione.
4. PLS-DA ha costruito un modello discriminante globale ottimizzato per separare le classi, con interpretazione diretta tramite coefficienti di regressione e VIP scores.
5. Lo sbilanciamento delle classi (SA dominante con 54% dei campioni) e' un fattore da considerare: le metriche di efficienza ($\sqrt{\text{Sens} \times \text{Spec}}$) sono piu' informative dell'accuracy globale per valutare le prestazioni per classe.
6. La cross-validazione venetian blinds ha permesso di selezionare la complessita' ottimale evitando l'overfitting, con validazione finale su test set indipendente stratificato.

Raccomandazioni operative:

- Per applicazioni di autenticazione alimentare (es. verificare se un olio e' genuinamente taggiasco), si raccomanda SIMCA per la sua capacita' di rifiutare campioni non conformi.
- Per la classificazione routinaria dell'origine geografica tra le 5 regioni note, PLS-DA offre tipicamente prestazioni migliori e una interpretazione piu' diretta.
- Le variabili con $\text{VIP} > 1$ e alto Discriminant Power (tipicamente oleico, linoleico, palmitoleico) sono i marker piu' informativi e potrebbero essere sufficienti per un protocollo analitico semplificato.
- Per un sistema di classificazione robusto in produzione, si consiglierebbe di utilizzare entrambi i metodi in cascata: SIMCA per la verifica di conformita' (il campione e' un olio d'oliva italiano autentico?) seguita da PLS-DA per l'assegnazione della regione specifica.