

# Analisi di Classificazione Olio di Oliva Italiano

SIMCA & PLS-DA

---

Corso: Elaborazione Dati Scientifici

A.A. 2024-2025

Data: 17/02/2026

*Dataset: Olive Oil (382 campioni, 7 acidi grassi, 5 regioni italiane)*

# Indice

---

## 1. Introduzione e Descrizione del Dataset

## 2. Fondamenti Teorici

- 2.1 Analisi delle Componenti Principali (PCA)
- 2.2 SIMCA (Soft Independent Modelling of Class Analogy)
- 2.3 PLS-DA (Partial Least Squares Discriminant Analysis)

## 3. Analisi Esplorativa dei Dati (EDA)

- 3.1 Distribuzione delle variabili
- 3.2 Matrice di correlazione
- 3.3 Analisi PCA esplorativa

## 4. Classificazione con SIMCA

- 4.1 Cross-validazione e scelta delle componenti
- 4.2 Modello finale e predizioni
- 4.3 Potere discriminante

## 5. Classificazione con PLS-DA

- 5.1 Cross-validazione e scelta delle variabili latenti
- 5.2 Modello finale e predizioni
- 5.3 Importanza delle variabili (VIP)

## 6. Confronto dei Metodi e Conclusioni

# 1. Introduzione e Descrizione del Dataset

---

Il presente report documenta l'analisi di classificazione completa eseguita sul dataset Olive Oil. L'obiettivo è discriminare campioni di olio d'oliva provenienti da 5 diverse regioni italiane sulla base della loro composizione in acidi grassi, utilizzando due metodi di classificazione complementari: SIMCA (class modeling) e PLS-DA (discriminant analysis).

## Dataset

Il dataset contiene 382 campioni di olio d'oliva italiano caratterizzati da 7 variabili che rappresentano la concentrazione percentuale di acidi grassi:

- Acido Palmitico (C16:0)
- Acido Palmitoleico (C16:1)
- Acido Stearico (C18:0)
- Acido Oleico (C18:1, monoinsaturo)
- Acido Linoleico (C18:2, polinsaturo omega-6)
- Acido Eicosanoico (C20:0)
- Acido Linolenico (C18:3, polinsaturo omega-3)

## Classi

I campioni appartengono a 5 aree geografiche italiane:

- NA - North Apulia (Puglia Nord): 25 campioni
- SA - South Apulia (Puglia Sud): 206 campioni
- U - Umbria: 51 campioni
- EL - East Liguria (Liguria Est): 50 campioni
- WL - West Liguria (Liguria Ovest, Taggiasche): 50 campioni

Si nota un forte sbilanciamento delle classi: la classe SA (South Apulia) contiene più della metà dei campioni totali ( $206/382 = 54\%$ ). Questo aspetto va tenuto in considerazione nell'interpretazione dei risultati di classificazione.

Il dataset è stato suddiviso in training set (70%) e test set (30%) con campionamento stratificato per mantenere le proporzioni delle classi.

## 2. Fondamenti Teorici

### 2.1 PCA - Analisi delle Componenti Principali

La PCA (Principal Component Analysis) è una tecnica di riduzione della dimensionalità che trasforma le variabili originali correlate in un nuovo set di variabili non correlate chiamate Componenti Principali (PC). Le PC sono ordinate per varianza spiegata decrescente. La PCA viene utilizzata sia come strumento esplorativo sia come base per la classificazione SIMCA.

La decomposizione è:  $X = T \cdot P' + E$ , dove  $T$  sono gli scores (coordinate dei campioni nello spazio ridotto),  $P$  i loadings (contributo delle variabili originali), ed  $E$  i residui.

### 2.2 SIMCA - Soft Independent Modelling of Class Analogy

SIMCA è un metodo di class modeling: costruisce un modello PCA indipendente per ciascuna classe, definendo i confini di appartenenza tramite limiti statistici sulle distanze. Le caratteristiche principali sono:

- Soft: nessuna assunzione sulla distribuzione delle variabili
- Independent: ogni classe ha il proprio modello PCA indipendente
- Modeling: il modello matematico è basato sulle componenti principali
- Un campione può essere assegnato a una, più classi, o nessuna classe

Per ogni campione si calcolano due distanze rispetto al modello di ciascuna classe:

- Score Distance (SD): distanza nello spazio delle PC, misurata dalla statistica  $T^2$  di Hotelling
- Orthogonal Distance (OD): distanza dal modello PCA, misurata dalla statistica  $Q$

Il criterio di appartenenza combinato è:

$$D = \sqrt{(T^2/T^2_{lim})^2 + (Q/Q_{lim})^2}$$

Un campione appartiene alla classe se  $D \leq \sqrt{2}$ .

Il Discriminant Power misura la capacità di ciascuna variabile di discriminare tra le classi.

### 2.3 PLS-DA - Partial Least Squares Discriminant Analysis

PLS-DA è un metodo discriminante basato sulla regressione PLS nella quale la matrice  $Y$  contiene variabili dummy (codifica 1/0) che rappresentano l'appartenenza alle classi. A differenza di SIMCA, PLS-DA cerca esplicitamente i confini che separano le diverse classi.

L'algoritmo NIPALS (Nonlinear Iterative Partial Least Squares) decompone simultaneamente  $X$  e  $Y$  trovando variabili latenti (LVs) che massimizzano la covarianza tra  $X$  e  $Y$ :

$$X = T \cdot P' + E$$

$$Y = T \cdot B \cdot Q' + F$$

La classificazione avviene assegnando il campione alla classe con il valore  $Y$  predetto più alto (criterio True Discriminant). I coefficienti di regressione  $B_{PLS} = W \cdot (P'W)^{-1} \cdot \text{diag}(b) \cdot Q'$  e i VIP scores (Variable Importance in Projection) permettono l'interpretazione delle variabili più importanti per la discriminazione.

## Metriche di Valutazione

Per entrambi i metodi si utilizzano le seguenti metriche:

- Sensitivity (Sensibilità):  $TP/(TP+FN)$  - % campioni correttamente classificati per ogni classe
- Specificity (Specificità):  $TN/(TN+FP)$  - % campioni correttamente rifiutati
- Efficiency (Efficienza):  $\sqrt{Sensitivity * Specificity}$
- Accuracy: % totale di campioni correttamente classificati

La cross-validazione (venetian blinds, 5 segmenti) viene utilizzata per selezionare il numero ottimale di componenti (PC per SIMCA, LV per PLS-DA) e per ottenere una stima non biased delle prestazioni del modello.

## 3. Analisi Esplorativa dei Dati (EDA)

### 3.1 Distribuzione delle Variabili

Il boxplot delle variabili grezze mostra le distribuzioni dei 7 acidi grassi. L'acido oleico (C18:1) presenta i valori piu' elevati (mediamente 75-80%) ed e' caratteristico degli oli d'oliva. Le altre variabili hanno valori molto piu' bassi.

*Figura 1: Distribuzione delle variabili (acidi grassi) nel dataset completo.*

La distribuzione per classe evidenzia le differenze tra le regioni. Variabili come l'acido palmitoleico e l'acido linoleico mostrano patterns diversi tra le aree geografiche, suggerendo il loro potenziale discriminante.




Figura 2: Distribuzione delle variabili suddivisa per classe (regione geografica).

### 3.2 Matrice di Correlazione

La matrice di correlazione rivela le relazioni lineari tra le variabili. Si possono osservare correlazioni significative tra alcuni acidi grassi, in particolare tra oleico e linoleico (correlazione inversa), che riflettono la biochimica della sintesi degli acidi grassi nella pianta di olivo.




Figura 3: Matrice di correlazione di Pearson tra i 7 acidi grassi.

### 3.3 Analisi PCA Esplorativa

La PCA sul dataset completo (autoscalato) permette di visualizzare la struttura naturale dei dati in spazi di dimensionalita' ridotta.

#### Scree Plot e Varianza Spiegata

Lo scree plot mostra che le prime 2-3 componenti principali catturano la maggior parte della varianza totale. Il grafico cumulativo indica quante PC sono necessarie per raggiungere una soglia prefissata (es. 95%) di varianza spiegata.




Figura 4: Scree plot e varianza cumulativa spiegata dalle componenti principali.

#### Score Plots

I grafici degli scores mostrano i campioni proiettati nello spazio delle PC. La separazione tra i cluster colorati per regione indica il potere discriminante della composizione in acidi grassi. Campioni della stessa regione tendono a raggrupparsi, confermando che la composizione degli acidi grassi e' un buon descrittore dell'origine geografica dell'olio.




Figura 5: PCA Score plots - PC1 vs PC2 (sinistra) e PC1 vs PC3 (destra).






Figura 6: PCA Score plot 3D (PC1 vs PC2 vs PC3).

## Loading Plots

I loadings indicano il contributo di ciascuna variabile originale alle componenti principali. Variabili con loadings elevati (in valore assoluto) sono quelle che piu' contribuiscono alla separazione dei campioni lungo quella PC. Il loading plot in spazio PC1-PC2 permette di interpretare la relazione tra variabili e la direzione delle separazioni osservate nello score plot.




Figura 7: Loading bar plot (sinistra) e loading plot PC1-PC2 (destra).

## 4. Classificazione con SIMCA

### 4.1 Cross-validazione e Scelta delle Componenti

La cross-validazione (venetian blinds, 5 segmenti) e' stata eseguita per selezionare il numero ottimale di PC per ciascun modello di classe. Per ogni numero di PC (da 1 a 6), si calcolano sensibilità, specificità ed efficienza per ciascuna classe.

Il criterio di selezione e' la massima efficienza in CV per ciascuna classe indipendentemente. Questo permette a classi diverse di avere dimensionalità diverse, coerentemente con la filosofia SIMCA di modellazione indipendente.




Figura 8: Metriche di classificazione SIMCA in cross-validazione al variare del numero di PC.

Dal grafico si seleziona per ciascuna classe il numero di PC che massimizza l'efficienza. La sensibilità misura quanti campioni della classe vengono correttamente accettati, mentre la specificità misura quanti campioni delle altre classi vengono correttamente rifiutati.

### 4.2 Modello Finale e Predizioni

Il modello SIMCA finale viene costruito con il numero ottimale di PC per ciascuna classe e validato sul test set esterno. I grafici SD vs OD mostrano per ciascun modello di classe la posizione dei campioni rispetto ai limiti di accettazione.




Figura 9: SIMCA - Score Distance vs Orthogonal Distance per il modello della Classe 1 (North Apulia). Cerchi = training, Diamanti = test. La curva rossa delimita la regione di accettazione ( $D \leq \sqrt{2}$ ).




Figura 10: SIMCA - Score Distance vs Orthogonal Distance per il modello della Classe 2 (South Apulia). Cerchi = training, Diamanti = test. La curva rossa delimita la regione di accettazione ( $D \leq \sqrt{2}$ ).




Figura 11: SIMCA - Score Distance vs Orthogonal Distance per il modello della Classe 3 (Umbria). Cerchi = training, Diamanti = test. La curva rossa delimita la regione di accettazione ( $D \leq \sqrt{2}$ ).




Figura 12: SIMCA - Score Distance vs Orthogonal Distance per il modello della Classe 4 (East Liguria). Cerchi = training, Diamanti = test. La curva rossa delimita la regione di accettazione ( $D \leq \sqrt{2}$ ).




Figura 13: SIMCA - Score Distance vs Orthogonal Distance per il modello della Classe 5 (West Liguria). Cerchi = training, Diamanti = test. La curva rossa delimita la regione di accettazione ( $D \leq \sqrt{2}$ ).

I campioni all'interno della curva rossa (cerchio di raggio  $\sqrt{2}$ ) nello spazio normalizzato SD/OD) sono accettati dal modello della classe corrispondente. Campioni fuori dalla curva sono rifiutati.

## Matrice di Confusione

Le matrici di confusione riassumono le prestazioni del classificatore SIMCA sul training set e sul test set. Gli elementi diagonali rappresentano le classificazioni corrette (True Positives), mentre gli elementi extra-diagonali rappresentano gli errori.




Figura 14: Matrici di confusione SIMCA per training set (sinistra) e test set (destra).

| SIMCA Summary |      |            |            |           |           |           |          |
|---------------|------|------------|------------|-----------|-----------|-----------|----------|
| Class         | nPCs | Sens_Train | Spec_Train | Eff_Train | Sens_Test | Spec_Test | Eff_Test |
| North Apulia  | 3    | 1          | 0.9960     | 0.9980    | 1         | 0.9907    | 0.9953   |
| South Apulia  | 4    | 1          | 1          | 1         | 1         | 0.9615    | 0.9806   |
| Umbria        | 2    | 1          | 1          | 1         | 0.9333    | 1         | 0.9661   |
| East Liguria  | 6    | 0.9714     | 0.9957     | 0.9835    | 0.9333    | 0.9899    | 0.9612   |
| West Liguria  | 1    | 0.9714     | 1          | 0.9856    | 0.8667    | 1         | 0.9309   |

Figura 15: Tabella riassuntiva delle metriche SIMCA per classe.

### 4.3 Potere Discriminante e Loadings

Il Discriminant Power misura la capacita' di ciascuna variabile di discriminare tra le classi nel modello SIMCA. E' calcolato come il rapporto tra i residui dei campioni non appartenenti alla classe e quelli appartenenti. Variabili con discriminant power superiore ai percentili 95 o 99 sono particolarmente efficaci nella discriminazione.




Figura 16: SIMCA Discriminant Power per ciascun acido grasso.

I loadings dei modelli PCA per ciascuna classe mostrano come le variabili contribuiscono alla struttura interna di ogni classe. Differenze nei loadings tra classi indicano che le classi hanno strutture di covarianza diverse.




Figura 17: SIMCA Loadings per ciascuna classe e componente principale.

## 5. Classificazione con PLS-DA

### 5.1 Cross-validazione e Scelta delle Variabili Latenti

La cross-validazione PLS-DA (venetian blinds, 5 segmenti) e' stata eseguita variando il numero di variabili latenti (LV) da 1 a 10. Per ogni numero di LV si calcolano gli errori di classificazione in CV usando il criterio True Discriminant (assegnazione alla classe con Y predetto piu' alto).

NOTA: il trend dell'RMSECV puo' non corrispondere esattamente al trend degli errori di classificazione in CV, poiche' le Y predette sono valori continui mentre le Y di classe sono variabili dummy discrete (1/0).




Figura 18: PLS-DA Cross-Validation: % corrette per classe, errori per classe, e metriche aggregate.






Figura 19: RMSECV (Root Mean Square Error of Cross-Validation) per classe al variare del numero di LV.

Il numero ottimale di LV è selezionato minimizzando il numero totale di campioni mal classificati in cross-validazione, garantendo un minimo di 2 LV per consentire la visualizzazione degli scores.

## 5.2 Modello Finale e Predizioni

Il modello PLS-DA finale viene costruito con il numero ottimale di LV sul training set completo. La classificazione avviene assegnando ogni campione alla classe con il valore più alto di Y predetto (True Discriminant rule).

### Y Predetto vs Campioni

I grafici delle Y predette mostrano, per ciascuna variabile di risposta (classe), il valore predetto dal modello per ogni campione. I campioni appartenenti alla classe (simboli pieni) dovrebbero avere valori superiori a 0.5, mentre gli altri dovrebbero avere valori inferiori. La linea rossa tratteggiata indica la soglia 0.5.




Figura 20: PLS-DA - Valori Y predetti per ogni classe sul training set.




Figura 21: PLS-DA - Valori Y predetti per ogni classe sul test set.

## Matrice di Confusione

Le matrici di confusione PLS-DA mostrano le prestazioni di classificazione. A differenza di SIMCA, PLS-DA assegna sempre ogni campione esattamente a una classe (non sono possibili assegnazioni multiple o rifiuti).




Figura 22: Matrici di confusione PLS-DA per training set e test set.

## PLS Scores

Gli scores PLS mostrano la proiezione dei campioni nello spazio delle variabili latenti. A differenza della PCA, le LV sono costruite per massimizzare la separazione tra classi (attraverso la covarianza con Y), quindi la separazione può risultare migliore rispetto allo score plot PCA.




Figura 23: PLS-DA Score plots (LV1 vs LV2) per training set e test set.

## 5.3 Importanza delle Variabili

I coefficienti di regressione PLS indicano il peso di ciascuna variabile nella predizione di ciascuna classe. Variabili con coefficienti alti (in valore assoluto) sono le più importanti per discriminare quella specifica classe.




Figura 24: Coefficienti di regressione PLS-DA per ciascuna classe.

I VIP scores (Variable Importance in Projection) forniscono una misura globale dell'importanza di ciascuna variabile nella classificazione. Variabili con  $VIP > 1$  sono considerate importanti, mentre variabili con  $VIP < 0.8$  sono considerate poco influenti.




Figura 25: VIP scores - Importanza delle variabili nella proiezione PLS-DA.

| PLS-DA Summary (7 LVs) |            |            |           |           |           |          |        |
|------------------------|------------|------------|-----------|-----------|-----------|----------|--------|
| Class                  | Sens_Train | Spec_Train | Eff_Train | Sens_Test | Spec_Test | Eff_Test | RMSEP  |
| North Apulia           | 0.5000     | 1          | 0.7071    | 0.4286    | 1         | 0.6547   | 0.6488 |
| South Apulia           | 1          | 0.9839     | 0.9919    | 1         | 0.9808    | 0.9903   | 0.1534 |
| Umbria                 | 0.9722     | 0.9828     | 0.9775    | 1         | 0.9697    | 0.9847   | 0.3663 |
| East Liguria           | 0.8000     | 0.9700     | 0.8809    | 0.8667    | 1         | 0.9309   | 0.4653 |
| West Liguria           | 1          | 0.9828     | 0.9914    | 1         | 0.9798    | 0.9898   | 0.3119 |

Figura 26: Tabella riassuntiva delle metriche PLS-DA per classe.

## 6. Confronto dei Metodi e Conclusioni

### 6.1 Confronto SIMCA vs PLS-DA

I due metodi hanno approcci fondamentalmente diversi alla classificazione:

SIMCA (Class Modeling):

- Costruisce modelli PCA indipendenti per ciascuna classe
- Può rifiutare campioni o assegnarli a più classi
- Adatto quando è importante verificare l'appartenenza a una specifica classe
- Ogni classe può avere dimensionalità (numero di PC) diversa

PLS-DA (Discriminant Analysis):

- Costruisce un unico modello focalizzato sulle differenze tra classi
- Assegna sempre ogni campione a esattamente una classe
- Adatto quando esistono classi ben definite e si vuole discriminare tra esse
- Fornisce strumenti interpretativi come VIP e coefficienti di regressione




Figura 27: Confronto sensibilità e specificità sul test set tra SIMCA e PLS-DA.

### 6.2 Conclusioni

L'analisi di classificazione del dataset Olive Oil ha dimostrato che la composizione in acidi grassi contiene informazione sufficiente per discriminare l'origine geografica dell'olio d'oliva italiano. Entrambi i metodi (SIMCA e PLS-DA) hanno mostrato buone prestazioni di classificazione.

Punti chiave:

- La PCA esplorativa ha mostrato la presenza di clusters naturali nel dataset
- Alcune classi (es. Liguria) si separano bene, mentre altre si sovrappongono parzialmente
- Lo sbilanciamento delle classi (SA dominante) può influenzare le prestazioni
- La cross-validazione ha permesso di selezionare la complessità ottimale dei modelli
- L'analisi delle variabili importanti (discriminant power, VIP) indica quali acidi grassi sono più utili per la discriminazione geografica

Per applicazioni pratiche di autenticazione alimentare, si raccomanda di utilizzare SIMCA quando l'obiettivo è verificare se un campione appartiene a una specifica denominazione di origine, e PLS-DA quando si vuole identificare la provenienza tra un set predefinito di regioni.