

Analisi di Classificazione tramite modelli PLS-DA e SIMCA sul dataset Olive Oil

ELABORAZIONE DEI DATI SCIENTIFICI

[262-009]

Autore:

Testoni Manuel (219155)

February 18, 2026

Contents

1	Introduzione	5
1.1	Contesto del dataset	5
1.2	Obiettivi dell'analisi	5
1.3	Metodologia	5
2	Esplorazione dei dati	7
2.1	Importazione e comprensione del dataset	7
2.2	Statistiche descrittive	7
3	PCA	9
3.1	Scelta del numero delle PC	9
3.2	Score Plot	10
3.3	Loadings Plot	11
4	PLS-DA	13
4.1	Fondamenti Teorici	13
4.2	Cross Validazione e RMSECV	13
4.2.1	Errore di Classificazione in CV	13
4.2.2	RMSECV per classe	14
4.3	Matrici di Confusione PLS-DA	15
4.3.1	Coefficienti di Regressione PLS	15
4.3.2	Variable Importance	16
5	SIMCA	19
5.1	Fondamenti Teorici	19
5.2	Score Distance VS Orthogonal Distance	19
5.3	Matrice di Confusione	24
5.4	Discriminant Power	25
5.5	Matrice di Confusione	25
5.6	Loadings per Classe	25
6	Confronto e Conclusioni	27
6.0.1	Confronto	27
6.0.2	Conclusioni	28
	References	29

1

Introduzione

1.1 Contesto del dataset

Il dataset in questione contiene i dati relativi agli olii d'oliva provenienti da varie regioni di Italia. Sono presenti all'interno 382 campioni, ognuno dei quali presenta 8 feature:

- Sigla di provenienza
- Acido Grasso Palmitico
- Acido Grasso Palmitoleico
- Acido Grasso Stearico
- Acido Grasso Oleico
- Acido Grasso Linoleico
- Acido Grasso Eicosanoico
- Acido Grasso Linolenico

Un'osservazione preliminare che si può fare a partire dal dataset è che questo non è bilanciato, ovvero vediamo come il numero di campioni per ogni regione non sia il medesimo.

Le regioni di provenienza dell'olio sono: **SA** (sud puglia); **NA** (nord puglia); **WL** (liguria ovest); **EL** (liguria est); **U** (Umbria)

1.2 Obiettivi dell'analisi

Partendo dal dataset Olive Oil già conosciuto in precedenza, realizzare due modelli di classificazione PLS-DA e SIMCA in grado di predire correttamente, sulla base di un training set, i dati del test set. Infine una validazione e un confronto dei modelli realizzati.

1.3 Metodologia

Per applicare le varie metodologie discusse in aula sono state implementate soluzioni in **Matlab** [1] affiancadoci al PLS-Toolbox.

2

Esplorazione dei dati

2.1 Importazione e comprensione del dataset

Oltre ad osservare che il dataset non è bilanciato come detto in precedenza, siamo anche in grado di dire che non vi sono valori mancanti o anomali.

2.2 Statistiche descrittive

È stata condotta un'analisi preliminare per avere come riferimento i range e la media delle variabili. Nella tabella qua sotto è possibile osservare questi parametri raggruppati per ogni singolo acido grasso.

Table 2.1: Statistiche descrittive per ciascun acido grasso.

Acido grasso	Minimo	Massimo	Media
Palmitico	6.10	17.53	12.526
Palmitoleico	0.15	2.80	1.363
Stearico	1.52	3.50	2.204
Oleico	63.00	84.10	73.193
Linoleico	5.10	14.62	9.625
Eicosanoico	0.00	0.70	0.301
Linolenico	0.00	1.02	0.518

3

PCA

3.1 Scelta del numero delle PC

Siamo in un dataset di 7 variabili quindi il numero massimo di componenti principali che potremo prendere sarà 7. Notiamo però dallo scree plot, che abbiamo un "gomito" significativo verso la terza PCA che ci permetterà di spiegare il 90% della varianza del nostro dataset. Abbiamo quindi diminuito la dimensionalità da 7 variabili a 3.




Figure 3.1: Scree plot (sinistra) e varianza cumulativa (destra) delle componenti principali.

3.2 Score Plot

I grafici degli scores proiettano i 382 campioni nello spazio ridotto delle PC. I campioni sono colorati per classe e visualizzati come scatter plot. Il pannello sinistro mostra PC1 vs PC2, quello destro PC1 vs PC3. Le etichette degli assi riportano la percentuale di varianza spiegata.




Figure 3.2: Score plots PCA - PC1 vs PC2 (sinistra) e PC1 vs PC3 (destra), colorati per classe.

Analisi dello score plot PC1 vs PC2: - Le classi liguri (EL ed WL) tendono a raggrupparsi in una regione dello spazio a valori positivi/negativi di PC1, separate dalle classi pugliesi. - La classe SA (South Apulia), essendo la più numerosa, forma un cluster ampio e denso. - La classe NA (North Apulia) mostra una distribuzione più dispersa, potenzialmente parzialmente sovrapposta con SA, il che è atteso data la prossimità geografica. - L'Umbria (U) tende a posizionarsi in una regione intermedia, riflettendo la sua posizione geografica tra il Sud e il Nord. - La separazione lungo PC2 aggiunge discriminazione extra, differenziando ulteriormente le classi che appaiono sovrapposte nella sola dimensione PC1. Analisi dello score plot PC1 vs PC3: - La terza PC cattura varianza complementare che può separare classi non distinguibili nel piano PC1-PC2. In particolare, la separazione tra EL e WL (entrambe liguri) potrebbe emergere lungo PC3, così come una migliore separazione tra NA e SA.

3.3 Loadings Plot

Il pannello sinistro mostra un bar chart dei loadings delle prime tre PC (PC1, PC2, PC3), con una barra per ciascuna variabile raggruppata per PC. Il pannello destro mostra il loading plot nello spazio PC1-PC2, dove ciascuna variabile è rappresentata come un vettore dall'origine, con il cerchio unitario come riferimento.




Figure 3.3: Loading bar chart PC1-PC3 (sinistra) e Loading plot PC1 vs PC2 (destra).

Interpretazione dei loadings: Bar chart (pannello sinistro): - PC1: dominata dall'opposizione oleico (loading negativo o positivo elevato) vs linoleico (segno opposto). Palmitoleico contribuisce nella stessa direzione del linoleico. Questo conferma che la principale sorgente di variazione è la composizione oleico/linoleico. - PC2: cattura la variazione in palmitoleico, stearico e potenzialmente eicosanoico, ortogonale all'asse oleico-linoleico. - PC3: variabili minori come linolenico, eicosanoico e stearico contribuiscono maggiormente, catturando varianza residua non rappresentata dalle prime due PC. Loading plot (pannello destro): - Il cerchio unitario grigio tratteggiato indica il raggio massimo ($r=1$). Variabili vicine al cerchio sono ben rappresentate nello spazio PC1-PC2; variabili vicine all'origine sono mal rappresentate e richiedono PC aggiuntive. - Oleico e Linoleico si trovano in direzioni opposte (anticorrelazione), confermando la struttura biochimica nota. - La prossimità di Palmitoleico al Linoleico nello spazio dei loadings indica che queste variabili co-variano nello stesso senso. - Eicosanoico e Linolenico, essendo vicini all'origine, sono scarsamente rappresentati nelle prime due PC e la loro informazione è catturata da PC successive.

4

PLS-DA

4.1 Fondamenti Teorici

PLS-DA è un metodo discriminante che combina la regressione PLS con la codifica dummy delle classi. La matrice Y contiene variabili indicatrici binarie (1/0) che codificano l'appartenenza alle classi. L'algoritmo NIPALS (Nonlinear Iterative Partial Least Squares) decompone simultaneamente X e Y: $X = T \cdot P' + E$ $Y = U \cdot Q' + F$. Le variabili latenti (LV) sono scelte per massimizzare la covarianza tra X e Y, quindi sono intrinsecamente orientate alla discriminazione. La predizione avviene tramite: $Y_{pred} = X_{new} \cdot B_{PLS} + \text{mean}(Y)$ dove $B_{PLS} = W \cdot (P'W)^{-1} \cdot \text{diag}(b) \cdot Q'$ sono i coefficienti di regressione. La classificazione si basa sul criterio True Discriminant: ogni campione viene assegnato alla classe corrispondente al valore massimo di Y predetto. A differenza di SIMCA, PLS-DA assegna sempre ogni campione a esattamente una classe (hard classification). I VIP scores (Variable Importance in Projection) misurano l'importanza globale di ciascuna variabile nella proiezione PLS, ponderata per la varianza di Y spiegata da ciascuna LV.

4.2 Cross Validazione e RMSECV

4.2.1 Errore di Classificazione in CV

La figura mostra 4 pannelli che visualizzano le prestazioni PLS-DA in cross-validazione al variare del numero di variabili latenti (LV) da 1 a 10: 1) % Correct Classification (alto-sx): la percentuale di campioni correttamente classificati per ciascuna delle 5 classi. Ciascuna classe ha la propria curva colorata. L'obiettivo è massimizzare queste percentuali. 2) Misclassified Samples (basso-sx): il numero assoluto di campioni mal classificati per classe. Complemento del pannello precedente, utile per capire l'entità assoluta degli errori. 3) Mean % Correct (alto-dx): la media delle percentuali corrette su tutte le classi, una singola curva blu. Questo è un indicatore globale unidimensionale delle prestazioni. 4) Total Misclassified (basso-dx): il numero totale di campioni mal classificati (somma su tutte le classi), una singola curva rossa. Il numero ottimale di LV è selezionato minimizzando questo valore.




Figure 4.1: PLS-DA Cross-Validation: percentuali corrette per classe, errori e metriche aggregate.

4.2.2 RMSECV per classe

Il grafico RMSECV (Root Mean Square Error of Cross-Validation) mostra l'errore di regressione in cross-validazione per ciascuna classe al variare del numero di LV. L'RMSECV misura quanto bene il modello predice i valori dummy (1/0) delle classi, non direttamente l'errore di classificazione. Una curva per ciascuna classe è tracciata, con marcatori circolari e legenda.




Figure 4.2: RMSECV per classe al variare del numero di variabili latenti.

La classe SA (più numerosa) può mostrare un RMSECV più basso semplicemente per la maggiore disponibilità di campioni per la stima. Classi piccole (NA) tendono ad avere RMSECV più alto e più variabile.

4.3 Matrici di Confusione PLS-DA

A differenza di SIMCA, PLS-DA assegna sempre ogni campione a esattamente una classe (hard classification): non esistono campioni 'rifiutati' o assegnati a più classi.




Figure 4.3: Matrici di confusione PLS-DA per training set e test set.

Interpretazione delle matrici di confusione PLS-DA: - Tutti i campioni sono assegnati a una (e una sola) classe, quindi il numero totale di campioni classificati corrisponde esattamente alla dimensione del dataset. - Errori tipici: confusione tra NA e SA (prossimità geografica pugliese), confusione occasionale tra EL e WL (prossimità ligure), confusione tra U e classi limitrofe. - Le prestazioni sul test set sono la misura più affidabile della capacità predittiva del modello, poiché non affette dal bias di autocalibrazione. - Una matrice di confusione con elementi diagonali dominanti e valori extra-diagonali nulli o molto bassi indica un classificatore eccellente

4.3.1 Coefficienti di Regressione PLS

La figura mostra 5 subplot orizzontali (1 per classe), ciascuno con un diagramma a barre dei coefficienti di regressione B_{PLS} per le 7 variabili. Il colore delle barre corrisponde alla classe (blu=NA, rosso=SA, verde=U, magenta=EL, arancione=WL). Le etichette X indicano i nomi degli acidi grassi.




Figure 4.4: Coefficienti di regressione PLS-DA per ciascuna classe.

- I coefficienti B_{PLS} rappresentano il 'peso' di ciascuna variabile nella predizione della Y dummy per ogni classe. - Coefficiente positivo: all'aumentare della variabile, aumenta la probabilità (Y predetto) di appartenenza alla classe. Coefficiente negativo: all'aumentare della variabile, diminuisce. - Il modulo (valore assoluto) indica l'importanza della variabile per quella specifica classe. - Confrontando i pattern tra le classi: variabili con segni opposti in classi diverse sono particolarmente discriminanti tra quelle classi. Ad esempio, se l'oleico ha coefficiente positivo per SA e negativo per EL, l'oleico è un buon discriminante SA vs EL. - La somma dei coefficienti di tutte le classi per una variabile non è necessariamente zero perché Y è mean-centered, non sommata a 1. - Variabili con coefficienti bassi in tutte le classi sono poco importanti per la classificazione.

4.3.2 Variable Importance

Il diagramma VIP (Variable Importance in Projection) mostra una barra per ciascuna delle 7 variabili, con due linee di riferimento - Linea rossa tratteggiata a $VIP=1$: soglia convenzionale di importanza. Variabili con $VIP > 1$ sono considerate importanti per la classificazione. - Linea nera puntinata a $VIP=0.8$: soglia inferiore. Variabili con $VIP < 0.8$ sono considerate poco influenti e potenziali candidate per l'eliminazione. Le barre sono colorate in verde per facilitare la lettura.




Figure 4.5: VIP scores - Importanza delle variabili nella proiezione PLS-DA.

Da questo grafico osserviamo come all'interno di questo dataset vi siano 3 variabili nettamente importanti mentre le altre 4 siano mediamente importanti per una corretta discriminazione.

5

SIMCA

5.1 Fondamenti Teorici

SIMCA è un metodo di class modeling: costruisce un modello PCA indipendente per ciascuna classe, definendo i confini di appartenenza tramite limiti statistici. Le caratteristiche fondamentali del metodo sono: - Soft: non fa assunzioni restrittive sulla distribuzione dei dati - Independent: ogni classe ha il proprio modello PCA con il proprio numero di componenti - Modeling: definisce lo spazio di ciascuna classe tramite un modello matematico - Un campione può essere accettato da più classi, una sola classe, o nessuna classe Per ogni campione si calcolano due distanze rispetto al modello di ciascuna classe: 1) Score Distance (SD): misurata dalla statistica T2 di Hotelling, quantifica quanto il campione è lontano dal centro della classe nello spazio delle PC. Segue una distribuzione F. 2) Orthogonal Distance (OD): misurata dalla statistica Q (somma dei quadrati dei residui), quantifica quanto il campione è lontano dal sottospazio PCA del modello. Il limite Q viene calcolato con l'approssimazione di Jackson-Mudholkar basata sugli autovalori residui. Il criterio di appartenenza combinato è: $D = \sqrt{(T2/T2lim)^2 + (Q/Qlim)^2} \leq \sqrt{2}$

5.2 Score Distance VS Orthogonal Distance

Per le classi di North-South Apulia, Umbria, East-West Liguria sono stati creati rispettivamente modelli PCA con 3,4,2,6,1 componenti principali.

Il metodo SIMCA (Soft Independent Modelling of Class Analogy) costruisce un modello PCA indipendente per ciascuna delle 5 classi. La selezione del numero ottimale di PC per classe avviene tramite cross-validazione (venetian blinds, 5 segmenti) sul training set, valutando PC da 1 a 6.

Per ciascuna delle 5 classi viene generato un grafico SD vs OD che rappresenta il piano diagnostico fondamentale del modello SIMCA. L'asse X riporta la Score Distance normalizzata ($T2/T2lim$), l'asse Y la Orthogonal Distance normalizzata ($Q/Qlim$). La curva rossa rappresenta il cerchio di raggio $\sqrt{2}$, ovvero il confine di accettazione: campioni all'interno della curva sono accettati dal modello della classe. I cerchi (o) rappresentano i campioni di training, i diamanti (d) pieni rappresentano i campioni di test, tutti colorati per classe.




Figure 5.1: Score Distance vs Orthogonal Distance per il modello della Classe 1 (North Apulia).

Per il modello della classe North Apulia, i campioni NA di training (cerchi blu) dovrebbero trovarsi all'interno del cerchio rosso. I campioni delle altre classi (SA, U, EL, WL) dovrebbero trovarsi all'esterno, indicando che il modello li rifiuta. Data la piccola numerosita' di NA (25 campioni, 18 in training), il modello potrebbe essere meno stabile. Eventuali campioni NA di test (diamanti blu) all'esterno segnalano falsi negativi, mentre campioni di altre classi all'interno segnalano falsi positivi. La posizione dei campioni rispetto ai due assi indica la natura dell'anomalia: alta SD = lontano dal centro nello spazio delle PC, alta OD = struttura diversa non catturata dal modello.




Figure 5.2: Score Distance vs Orthogonal Distance per il modello della Classe 12(South Apulia).

Il modello South Apulia è quello con più campioni di training (144). La classe SA, essendo la più numerosa ed eterogenea, potrebbe richiedere più PC per una descrizione adeguata. I campioni SA dovrebbero formare un cluster compatto all'interno del cerchio, mentre le classi liguri (EL, WL), avendo composizioni diverse, dovrebbero trovarsi ben al di fuori. La separazione SA/NA è meno netta per la prossimità geografica. Campioni con elevata OD indicano una struttura chimica non compatibile con il modello SA, mentre campioni con elevata SD hanno composizioni compatibili ma estreme.




Figure 5.3: Score Distance vs Orthogonal Distance per il modello della Classe 12(Umbria).

La stessa meccanica vale anche per i campioni di produzione umbra, il cui modello descrive una classe di dimensione intermedia (36 in training).




Figure 5.4: Score Distance vs Orthogonal Distance per il modello della Classe 12(East Liguria).

Il modello East Liguria mostra le distanze di tutti i campioni rispetto al modello PCA costruito sui campioni liguri orientali. Le classi EL e WL (entrambe liguri) potrebbero avere una sovrapposizione parziale, che si manifesta con campioni WL all'interno o vicino al confine del modello EL. I campioni pugliesi (NA, SA) sono chiaramente al di fuori, con OD elevata per la diversa struttura degli acidi grassi a patto di qualche eccezione.




Figure 5.5: Score Distance vs Orthogonal Distance per il modello della Classe 12(West Liguria).

Il modello West Liguria (Taggiasche) descrive una classe con composizione distintiva. Le olive taggiasche hanno un profilo di acidi grassi specifico che potrebbe rendere questa classe più compatta e ben separata. Questo ci permette di osservare una separazione ben accentuata.

5.3 Matrice di Confusione




Figure 5.6: Matrici di confusione SIMCA per training set (sinistra) e test set (destra).

- Diagonale: i numeri sulla diagonale indicano quanti campioni di ciascuna classe sono stati correttamente classificati. Percentuali alte sulla diagonale corrispondono ad alta sensibilità.
- Elementi extra-diagonali: indicano confusione tra le classi. Ad esempio, un valore alto nella cella (riga SA, colonna NA) indica che molti campioni NA sono stati classificati come SA. Questo tipo di errore rivela la somiglianza chimica tra le regioni.
- Confronto training vs test: il modello tipicamente performa meglio sul training set. Una degradazione significativa sul test set è segno di overfitting. SIMCA, essendo un metodo basato su modelli individuali per classe, è relativamente robusto all'overfitting, ma classi con pochi campioni (NA) possono mostrare instabilità.
- Si noti che in SIMCA un campione può essere rifiutato da tutte le classi (non accettato) o accettato da più classi. In caso di accettazione multipla, la regola di assegnazione tipicamente sceglie la classe con la distanza D minore.

5.4 Discriminant Power

Il Discriminant Power è un indice specifico di SIMCA che quantifica la capacità di ciascuna variabile di discriminare tra le classi. Viene calcolato come il rapporto medio tra i residui dei campioni non appartenenti alla classe e quelli appartenenti, mediato su tutte le coppie di classi. Il diagramma a barre mostra il valore per ciascuno dei 7 acidi grassi, con linee di riferimento orizzontali per il 95o percentile (verde), il 99o percentile (rosso) e la media (nero tratteggiato).

5.5 Matrice di Confusione




Figure 5.7: SIMCA Discriminant Power per ciascun acido grasso, con soglie percentili.

Da questo grafico siamo in grado di evincere come le variabili relative agli acidi grassi Linoelico e Oleico abbiano discriminato di più tra le classi di olii.

5.6 Loadings per Classe

L'analisi dei loadings per classe è fondamentale nella filosofia SIMCA: - Se i loadings delle diverse classi sono simili, le classi condividono la stessa struttura di covarianza e la discriminazione si basa principalmente sulle posizioni nello spazio scores.

- Se i loadings sono diversi tra le classi, le classi hanno strutture interne differenti, il che giustifica pienamente l'approccio SIMCA di modellazione indipendente.




Figure 5.8: SIMCA Loadings per ciascuna classe e componente principale.

6

Confronto e Conclusioni

I due metodi di classificazione adottano filosofie fondamentalmente diverse: SIMCA (Class Modeling): - Costruisce modelli PCA indipendenti per ciascuna classe - Può rifiutare campioni (nessuna classe li accetta) o assegnarli a più classi - Adatto quando l'obiettivo è verificare l'autenticità/appartenenza a una specifica classe - Ogni classe ha un proprio numero ottimale di PC - Fornisce il Discriminant Power come misura di importanza delle variabili - Robusto per campioni anomali o non appartenenti a nessuna classe nota PLS-DA (Discriminant Analysis): - Costruisce un unico modello focalizzato sulle differenze tra tutte le classi - Assegna sempre ogni campione a esattamente una classe (hard classification) - Adatto quando le classi sono ben definite e mutualmente esclusive - Un unico numero di LV per l'intero modello - Fornisce VIP scores e coefficienti di regressione per l'interpretazione - Tipicamente più potente quando le classi sono ben separate

6.0.1 Confronto

La figura mostra due pannelli affiancati con diagrammi a barre raggruppate: - Pannello sinistro (Test Set Sensitivity): per ciascuna classe, due barre che confrontano la sensibilità SIMCA (blu) e PLS-DA (rosso). Valori più alti indicano maggiore capacità di riconoscere correttamente i campioni della classe. - Pannello destro (Test Set Specificity): per ciascuna classe, due barre che confrontano la specificità SIMCA e PLS-DA. Valori più alti indicano maggiore capacità di rifiutare campioni non appartenenti. L'asse Y va da 0 a 1.1 per tutte le classi, permettendo un confronto diretto.




Figure 6.1: Confronto sensitività e specificità sul test set tra SIMCA e PLS-DA per classe.

Se PLS-DA mostra sensitività maggiori di SIMCA, il modello discriminante è più efficace nel riconoscere i campioni della classe. Ciò è comune quando le classi sono ben separate. - Se SIMCA mostra specificità

maggiori, il modello per classe è più selettivo nel rifiutare campioni estranei. Ciò è tipico e costituisce il punto di forza di SIMCA. - La classe NA (più piccola) potrebbe mostrare le maggiori differenze tra i due metodi a causa della scarsa numerosità che rende i modelli meno stabili. - Le classi SA (dominante) ed EL/WL (compatte e ben separate) tendono a performare bene con entrambi i metodi. - L'Umbria (U), geograficamente intermedia, potrebbe essere la classe più critica per entrambi i classificatori.

6.0.2 Conclusioni

L'analisi di classificazione del dataset Olive Oil ha dimostrato che la composizione in acidi grassi è un descrittore efficace dell'origine geografica dell'olio d'oliva italiano. SIMCA ha costruito modelli PCA indipendenti con complessità diversa per classe, fornendo una modellazione flessibile della struttura interna di ciascuna regione. PLS-DA ha costruito un modello discriminante globale ottimizzato per separare le classi, con interpretazione diretta tramite coefficienti di regressione e VIP scores.

Bibliography

- [1] The MathWorks, I. (2025). *MATLAB version 9.16.0 (R2025a)*. The MathWorks, Inc., Natick, Massachusetts, United States.